

Desenvolvimentos na estimação do campo de velocidade do som na água utilizando tempo de trânsito

Autor: Vitor G. P. Curtarelli

Revisores: Stephan Paul, Lucas C. Lobato

Data: 18 de maio de 2026

Entregável: 3.2.2 - Implementação dos algoritmos de TTT 2D/3D promissores identificados na Atividade 3.1

Resumo: Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Esse documento requer a leitura do relatório de revisão bibliográfica apresentado no Entregável 3.1.1, e [disponível no Overleaf](#).

1 Método padrão para *Travel-Time Tomography*

Aqui será descrito um método padrão para a estimação do campo de velocidade do som (SSF) utilizando a técnica *Travel-Time Tomography* (TTT), seguindo os artigos citados na Seção 2 da [revisão bibliográfica](#) [1] como guia. Diferenças em relação aos artigos podem surgir, como ignorar efeitos de *ray bending*, tipo de regularização empregada, quantidade e posição dos dispositivos, propósito da técnica, ou outras particularidades. A estrutura apresentada aqui não será idêntica a nenhum dos artigos citados, e busca destacar as similaridades e o ponto em comum deles.

1.1 Estrutura básica

Nós assumiremos que o modelo submarino a ser modelado é 2D por simplicidade, embora a formulação suporte aplicações 3D e 4D. Também modelaremos o ambiente como uma grade de células $N_z \times N_x$ (N_z divisões verticais, N_x divisões horizontais), com um total de $N = N_z \cdot N_x$ células. São alocadas fontes e receptores no ambiente, com comunicação de mão única entre eles, e comunicação apenas fonte-receptor.

Entre todas as fontes e receptores (ou entre alguns pares de dispositivos), um total de M raios (viagens fonte-receptor) são produzidos e mensurados; ou seja, possivelmente nem todas as fontes se comunicam com todos os receptores, e vice-versa, possibilitando modelar ambientes muito esparsos, tal que a comunicação entre dispositivos distantes não ocorre.

Denota-se $\mathbf{s} \in \mathbb{R}^{N \times 1}$ um vetor positivo representando a vagarosidade (*slowness*, inverso da velocidade) do som em cada célula, e $\mathbf{r}_m(\mathbf{s}) \in \mathbb{R}^{N \times 1}$ um vetor positivo, em que o i -ésimo valor de $\mathbf{r}_m(\mathbf{s})$ representa a distância percorrida pelo m -ésimo raio na i -ésima célula. O vetor $\mathbf{r}_m(\mathbf{s})$ é geralmente obtido externamente por meio de algum solver da Equação Eikonal (como FMM [2] ou FSM [3]), considerando o princípio de Fermat de tempo mínimo, e a lei de Snell.

Para o m -ésimo raio, o tempo de trânsito modelado $t_m(\mathbf{s})$ para o m -ésimo raio é

$$t_m(\mathbf{s}) = \mathbf{r}_m^T(\mathbf{s})\mathbf{s}. \quad (1)$$

Note que tanto o vetor de distâncias $\mathbf{r}_m(\mathbf{s})$ e o tempo de viagem $t_m(\mathbf{s})$ dependem do SSF $\mathbf{s}$, já que um campo diferente levaria a caminhos diferentes, e também a um tempo de trânsito diferente.

Considerando todos os M raios disponíveis, define-se $\mathbf{t}(\mathbf{s}) \in \mathbb{R}^{M \times 1}$ como um vetor dos tempos de trânsito para o modelo $\mathbf{s}$ atual; e $\mathbf{R}(\mathbf{s}) \in \mathbb{R}^{M \times N}$ uma matriz, em que a sua m -ésima linha é $\mathbf{r}_m^T(\mathbf{s})$. Ou seja,

$$\mathbf{t}(\mathbf{s}) = \mathbf{R}(\mathbf{s})\mathbf{s} \quad (2)$$

Por fim, denotamos $\mathbf{t}_{\text{obs}}$ como o vetor observado de tempo de trânsito, obtido a partir das medições de tempo de viagem (bidirecional) entre as fontes e os receptores. Com essas variáveis, o problema de minimização basal torna-se minimizar a função custo $E(\mathbf{s})$, isso traduzindo-se em

$$\mathbf{s}^* = \arg \min_{\mathbf{s}} E(\mathbf{s}) = \|\mathbf{R}(\mathbf{s})\mathbf{s} - \mathbf{t}_{\text{obs}}\|^2 \quad (3)$$

em que $\mathbf{s}^*$ é a solução ótima para a minimização estabelecida.

Note que esse problema é não-linear e recursivo: $\mathbf{R}(\mathbf{s})$ depende do campo de vagarosidade $\mathbf{s}$, e o modelo do campo $\mathbf{s}$ depende do resultado obtido pelo solver Eikonal $\mathbf{R}(\mathbf{s})$. Contudo, a solução $\mathbf{R}(\mathbf{s})$ não possui uma solução trivial, muito menos uma forma fechada, dificultando a obtenção de uma solução.

Posto isso, a solução é geralmente buscada iterativamente: dado $\mathbf{s}_i$ (na iteração i), obtém-se $\mathbf{R}(\mathbf{s}_i)$ através do solver Eikonal (esse sendo o PROBLEMA DIRETO); e dado $\mathbf{R}(\mathbf{s}_i)$, obtém-se $\mathbf{s}_{i+1}$ através da função-custo da Eq. (3) (esse sendo o PROBLEMA INVERSO), assumindo $\mathbf{R}(\mathbf{s}_i)$ como uma constante. Por notação, denota-se $\mathbf{R}_i \equiv \mathbf{R}(\mathbf{s}_i)$, explicitando a dependência de $\mathbf{R}$ em i .

O problema inverso é resolvido encontrando o mínimo da Eq. (3), que é remodelado da forma

$$\mathbf{s}_{i+1} = \arg \min_{\mathbf{s}_{i+1}} E(\mathbf{s}_{i+1}) = \|\mathbf{R}_i \mathbf{s}_{i+1} - \mathbf{t}_{\text{obs}}\|^2. \quad (4)$$

Note que agora esse problema é quadrático em $\mathbf{s}_{i+1}$, e sua solução pode ser obtida tomando seu gradiente e igualando a zero; ou seja,

$$\nabla E(\mathbf{s}_{i+1}) = 2\mathbf{R}_i^T (\mathbf{R}_i \mathbf{s}_{i+1} - \mathbf{t}_{\text{obs}}) = \mathbf{0}. \quad (5)$$

O problema direto (estimar $\mathbf{R}_i$ a partir de $\mathbf{s}_i$) é resolvido com algum solver Eikonal externamente. Assumindo invertibilidade de $\mathbf{R}_i^T \mathbf{R}_i$, então a solução da minimização é

$$\mathbf{s}_{i+1} = \mathbf{G}_i \mathbf{t}_{\text{obs}}, \quad (6a)$$

$$\mathbf{G}_i = [\mathbf{R}_i^T \mathbf{R}_i]^{-1} \mathbf{R}_i^T. \quad (6b)$$

Como $\mathbf{R}_i$ é atualizado repetitivamente, $\mathbf{G}_i$ também será, com uma solução iterativa.

1.2 Problemas da minimização

Para a Eq. (6) ser válida, é crucial que $\mathbf{R}_i^T \mathbf{R}_i$ seja uma matriz inversível, e também que sua inversão seja estável e bem-comportado.

Considerações sobre posto deficiente

Para a Eq. (6) ser válida, é crucial que $\mathbf{R}_i^T \mathbf{R}_i$ seja uma matriz inversível. Dado que $\mathbf{R}_i \in \mathbb{R}^{M \times N}$, então $\mathbf{R}_i^T \mathbf{R}_i \in \mathbb{R}^{N \times N}$; portanto, tem-se que $\text{rank}(\mathbf{R}_i) = N$ e $N \leq M$ são condições necessárias e suficientes para a inversão ser possível. Intuitivamente, isso traduz-se em haver mais medições M do que variáveis N , que ao menos N medições sejam significativas, e que cada célula seja representada (visitada) por ao menos um raio. Essas condições, embora factíveis, não são práticas ou por vezes verificáveis, e portanto não é seguro assumir que a inversão seja viável.

Nessas situações, algumas alternativas já foram apresentadas na literatura. As mais populares são a solução indireta com gradiente descendente [4–7], ou uso de funções de regularização [4–7]. Outra opção, que ainda não foi explorada na literatura no contexto de TTT, é utilizando a decomposição em valores singulares (SVD) [8, 9] para a inversão [10, 11], a ser explorada na Seção 2.

Esparsidade da matriz de distâncias

Além da inversão de $\mathbf{R}_i^\top \mathbf{R}_i$ necessitar que $\mathbf{R}_i$ seja posto-cheio, outro problema que pode surgir é devido a essa matriz ser esparsa. Assumindo que as ondas percorram caminhos bem comportados (monotônicos, sem reflexões), uma onda atravessará no máximo $N_x + N_z$ células, das $N_x \cdot N_z$ presentes no ambiente. Supondo que N_x e N_z sejam da mesma ordem de grandeza (com $N_x \approx N_y \approx \sqrt{N}$), então a proporção de entradas não-nulas em relação ao total de valores de $\mathbf{R}_i$ será de $1 : \frac{1}{2}\sqrt{N}$. Portanto, quanto maior o número de células, maior será a esparsidade da matriz $\mathbf{R}_i$.

$\mathbf{R}_i$ ser uma matriz esparsa pode causar uma série de problemas. Por exemplo, se determinada célula não for visitada por nenhum raio, a sua respectiva coluna em $\mathbf{R}_i$ será 0, fazendo com que essa matriz não seja posto-cheio, e portanto será não-inversível; a esparsidade de $\mathbf{R}_i$ aumenta a possibilidade de isso acontecer. Além disso, o número de condicionamento (que mede o quão instável é o problema linear definido por uma matriz) de uma matriz esparsa pode ser muito grande (ou infinito), o que acarreta em um problema muito sensível a pequenos erros na estimação das distâncias percorridas por cada raio.

1.3 Adição de regularização

Como citado, comumente o problema de estimação do SSF será um problema de inversão mal-posto; isso tanto para o caso $M > N$ ($\mathbf{R}_i^\top \mathbf{R}_i$ não é inversível), quanto por considerar que $\mathbf{R}_i$ é esparsa ($\mathbf{R}_i^\top \mathbf{R}_i$ não é inversível, ou a inversão é instável). Uma alternativa para tratar essas adversidades é a adição de regularização, simultaneamente aumentando as chances de uma solução estável e única ser encontrada, e melhorando alguma condição secundária, como suavidade, erro em comparação a um modelo-base, ou outras métricas. Escolher uma regularização adequada também pode ajudar a generalizar a solução encontrada para o caso contínuo, separando o problema de minimização da discretização espacial escolhida [12, 13].

A partir da Eq. (3), podemos adicionar um termo de regularização na forma de $P_\alpha(\mathbf{s}_{i+1})$, de modo que a forma iterativa de $\mathbf{s}_{i+1}$ das Eqs. (4) e (5) se torne

$$\mathbf{s}_{i+1} = \arg \min_{\mathbf{s}_{i+1}} E(\mathbf{s}_{i+1}) = \|\mathbf{R}_i \mathbf{s}_{i+1} - \mathbf{t}_{\text{obs}}\|^2 + P_\alpha(\mathbf{s}_{i+1}), \quad (7a)$$

$$\nabla E(\mathbf{s}_{i+1}) = 2\mathbf{R}_i^\top (\mathbf{R}_i \mathbf{s}_{i+1} - \mathbf{t}_{\text{obs}}) + \nabla P_\alpha(\mathbf{s}_{i+1}), \quad (7b)$$

com α sendo um parâmetro de controle.

O modelo mais comum para a função de regularização é uma regularização quadrática (também chamada regularização Tikhonov) $P_\alpha(\mathbf{s}_{i+1}) = \alpha^2 \|\mathbf{D} \mathbf{s}_{i+1}\|^2$, onde $\mathbf{D}$ é uma matriz quadrada. A solução para o problema regularizado é

$$\mathbf{G}_i = [\mathbf{R}_i^\top \mathbf{R}_i + \alpha^2 \mathbf{D}^\top \mathbf{D}]^{-1} \mathbf{R}_i^\top. \quad (8)$$

Para que esta etapa de inversão seja possível, basta que $\mathbf{D}$ seja uma matriz de posto completo¹. A matriz de regularização $\mathbf{D}$ pode ser escolhida para melhorar uma série de métricas.

Regularização RMS

Escolher $\mathbf{D} = \mathbf{I}$ (identidade) [14] resulta na minimização considerando também a raiz quadrada média (RMS) do vetor de vagarosidade; isso é equivalente a considerar a presença de ruído branco nas medições e trocar a precisão do modelo pela rejeição de ruído.

Regularização Laplaciana/de suavidade

Escolher $\mathbf{D}z \approx \nabla^2 s(x, y)$, aproximando (discretamente) o Laplaciano do SSF [4, 12], resulta em uma minimização que penaliza o Laplaciano do campo de vagarosidade obtido; isto é, uma solução que também considera a curvatura/saltos no SSF, buscando um campo mais suave.

¹Por definição, $\mathbf{R}_i^\top \mathbf{R}_i$ é uma matriz semidefinida positiva, $\mathbf{D}$ é definida positiva se $\mathbf{D}$ for uma matriz quadrada de posto completo, e a soma de uma matriz semidefinida positiva com uma matriz definida positiva é sempre definida positiva; esta sendo uma condição suficiente para a invertibilidade.

Outras regularizaes

Zhang et al. [12] tambm comenta brevemente sobre o uso de derivadas de terceiro grau em vez de derivadas de segundo grau (sendo estas timas a regularizao Laplaciana), o que tambm poderia resultar em uma boa suavizao do campo de velocidade. Hormati et al. [5] prope uma funo de regularizao baseada na representao ortonormal da distribuio de vagarosidade e nas normas L_0 ou L_1 .

Multi-regularizao

Outra possibilidade que ainda est em aberto para explorao  o uso de mtiplas funes de regularizao. Por exemplo, o uso combinado das duas funes apresentadas anteriormente (regularizao de rudo branco e penalizao Laplaciana) pode levar a uma boa suavidade na funo de distribuio de vagarosidade, mantendo um kernel invertvel garantido. Ou seja, dizemos que

$$E(\mathbf{s}_{i+1}) = \|\mathbf{R}_i \mathbf{s}_{i+1} - \mathbf{t}_{\text{obs}}\|^2 + \alpha^2 \|\mathbf{D} \mathbf{s}_{i+1}\|^2 + \beta^2 \|\mathbf{s}_{i+1}\|^2 \quad (9)$$

para o qual a soluo 

$$\mathbf{G}_i = \left[\mathbf{R}_i^\top \mathbf{R}_i + \alpha^2 \mathbf{D}^\top \mathbf{D} + \beta^2 \mathbf{I} \right]^{-1} \mathbf{R}_i^\top. \quad (10)$$

O termo entre colchetes  garantidamente definido positivo (Nota de rodap 1), e portanto seguramente invertvel.

Forma normalizada

Como $\mathbf{R}_i$ e $\mathbf{D}$ podem estar em ordens de magnitudes muito diferentes, pode ser til normaliz-las, de forma que o coeficiente α seja mais robustamente descrito. Denota-se $\rho = \|\mathbf{R}_i\|_F$ (tomando sua norma de Frobenius), e semelhantemente para $\delta = \|\mathbf{D}\|_F$. Com isso, denota-se $\dot{\mathbf{R}}_i = \frac{\mathbf{R}_i}{\rho}$, e da mesma forma para $\dot{\mathbf{D}} = \frac{\mathbf{D}}{\delta}$. A forma normalizada da soluo mono-regularizada da Eq. (8) , portanto,

$$\mathbf{G}_i = \frac{1}{\rho} \left[\dot{\mathbf{R}}_i^\top \dot{\mathbf{R}}_i + \alpha^2 \dot{\mathbf{D}}^\top \dot{\mathbf{D}} \right]^{-1} \dot{\mathbf{R}}_i^\top \quad (11)$$

em que α ser um valor diferente (mais especificamente, para o mesmo resultado, deveria ser usado $\alpha \frac{\delta}{\rho}$); contudo, por esse parmetro ser escolhido arbitrariamente, isso foi omitido.

1.4 Mdia convolucional/suavizao por desfoque

Outra ferramenta interessante encontrada na literatura [14, 15]  o uso de um DESFOQUE (blur) no gradiente. Esse desfoque (tambm chamada de mdia convolucional, ou dispersamento de raios) pode auxiliar na busca de solues ao espalhar os raios e os caminhos percorridos para clulas vizinhas, lidando assim com o problema de algumas clulas no serem atravessadas por nenhum raio. Ou seja, usamos $\bar{\mathbf{R}}_i = \mathbf{R}_i \mathbf{B}_i$, em que $\mathbf{B}_i$  uma matriz de desfoque (baseada em um desfoque Gaussiano, ou outro kernel de interesse), responsvel por espalhar a informao de cada clula de $\mathbf{R}_i$ para as clulas vizinhas.

Disso, o problema matemtico se torna

$$E(\mathbf{s}_{i+1}) = \|\bar{\mathbf{R}}_i \bar{\mathbf{s}}_{i+1} - \mathbf{t}_{\text{obs}}\|^2 + P_\alpha(\bar{\mathbf{s}}_{i+1}) \quad (12)$$

onde $\bar{\mathbf{s}}_{i+1} = \mathbf{B}_i^{-1} \mathbf{s}_{i+1}$, para que a soluo se mantenha no mesmo domnio que a original. Neste cenrio, a soluo $\mathbf{s}_{i+1}$ 

$$\mathbf{G}_i = \mathbf{B}_i \left[\mathbf{B}_i^\top \mathbf{R}_i^\top \mathbf{R}_i \mathbf{B}_i + \alpha^2 \mathbf{D}^\top \mathbf{D} \right]^{-1} \mathbf{B}_i^\top \mathbf{R}_i^\top \quad (13)$$

Para alcanar isso, a funo de regularizao precisa ser adaptada, de modo que $P_\alpha(\mathbf{s}_{i+1}) = \alpha^2 \|\mathbf{D} \mathbf{B}_i^{-1} \mathbf{s}_{i+1}\|^2$; isso significa que a regularizao  aplicada ao sinal $\bar{\mathbf{s}}_{i+1}$. A dependncia de $\mathbf{B}_i$ em relao ao iterador i indica que o raio de desfoque pode variar com i , geralmente diminuindo conforme iteraes passam, levando a um menor desfoque (e uma soluo mais refinada).

Em [4], uma estrutura de desfoque semelhante é proposta, mas esse desfoque é aplicado diretamente ao gradiente, de modo que

$$\nabla E(\mathbf{s}_{i+1}) = 2\mathbf{B}_i\mathbf{R}_i^\top (\mathbf{R}_i\mathbf{s}_{i+1} - \mathbf{t}_{\text{obs}}) + 2\alpha^2\mathbf{D}^\top\mathbf{D}\mathbf{s}_{i+1} \quad (14)$$

Como no artigo citado a solução $\mathbf{s}_{i+1}$ é encontrada pelo método do gradiente conjugado (iterativo), e não por inversão, a matriz de desfoque é variável dentro da busca iterativa do gradiente conjugado pela inversa (com iterador k), em vez do processo iterativo de resolução de Eikonal (iterador i). Assumindo invertibilidade, a solução pode ser obtida diretamente através de

$$\mathbf{G}_i = \left[\mathbf{B}_i\mathbf{R}_i^\top\mathbf{R}_i + \mathbf{D}^\top\mathbf{D} \right]^{-1} \mathbf{B}_i\mathbf{R}_i^\top \quad (15)$$

situação em que o desfoque pode ser atenuado em cada iteração de i , ou mesmo mantido constante.

Note que ambas as estruturas de suavização apresentadas requerem a presença de um termo de regularização — caso contrário, o termo inverso pode ser expandido e os termos $\mathbf{B}_i$ serão cancelados.

1.5 Outras ideias propostas

Esta seção reúne outras ideias propostas que não são abordadas na literatura apresentada, e que podem resultar em contribuições úteis.

1.5.1 Minimização ponderada

Na modelagem apresentada, assume-se que todas as medições são igualmente importantes, embora esse possa não ser o caso. Como exemplo, considere que algumas das medições foram realizadas quando o corpo d'água estava sendo perturbado por correntes fortes, afetando a posição dos sensores e a velocidade do som percebida na água. Essas medições ainda são úteis, mas seus dados são sabidamente (*a priori*) menos precisos e confiáveis do que os de outras medições, e portanto um passo de ponderação para essas medições pode ser adotado.

Matematicamente, isso é modelado adaptando a Eq. (4). Essa equação pode ser expandida e escrita como

$$\mathbf{s}_{i+1} = \arg \min_{\mathbf{s}} \sum_{m=0}^{M-1} \left(\mathbf{R}_{m,i}^\top \mathbf{s} - t_{\text{obs};m} \right)^2 \quad (16)$$

na qual $\mathbf{r}_{m,i}$ é um vetor das distâncias percorridas em cada célula pelo m -ésimo raio, na i -ésima iteração; e $t_{\text{obs};m}$ é o tempo total de percurso observado para o m -ésimo raio.

Com essa formulação, uma ponderação w_i pode ser adicionada a cada raio, levando a

$$\mathbf{s}_{i+1} = \arg \min_{\mathbf{s}} \sum_{m=0}^{M-1} w_m \left(\mathbf{R}_{m,i}^\top \mathbf{s} - t_{\text{obs};m} \right)^2 \quad (17)$$

onde $w_m > 0$ é o peso da m -ésima medição. Retornando à formulação matricial, obtemos

$$\mathbf{s}_{i+1} = \arg \min_{\mathbf{s}} \left\| \mathbf{W} (\mathbf{R}_i\mathbf{s} - \mathbf{t}_{\text{obs}}) \right\|^2 \quad (18)$$

onde $\mathbf{W}$ é uma matriz diagonal tal que $[\mathbf{W}]_{(m,m)} = \sqrt{w_m}$. Para esse caso, a solução será

$$\mathbf{s}_{i+1} = \left[\mathbf{R}_i^\top \mathbf{W}^\top \mathbf{W} \mathbf{R}_i \right]^{-1} \mathbf{R}_i^\top \mathbf{W}^\top \mathbf{W} \mathbf{t}_{\text{obs}} \quad (19)$$

Essa formulação também pode ser aliada à regularização, como detalhado na Seção 1.3, mas sem aplicar uma ponderação ao termo de regularização.

Super-modelagem espacial

Embora cenários em que $M > N$ (mais medições do que células discretas) sejam de interesse prático, isso exige uma grande distribuição de dispositivos, podendo não ser viável na prática. Portanto, a análise da teoria em cenários super-modelados (mais variáveis de modelo do que medições) pode ser útil para casos em que a resolução espacial nas células é mais fina do que a resolução física produzida pela distribuição dos dispositivos.

Em um cenário em que $M < N$, temos $\text{rank}(\mathbf{R}_i^\top \mathbf{R}_i) = \text{rank}(\mathbf{R}_i) = R \leq M$, e como $\mathbf{R}_i^\top \mathbf{R}_i \in \mathbb{R}^{N \times N}$, o produto é uma matriz deficiente em posto, sendo portanto garantidamente não invertível. Para o método-padrão estabelecido, isso força o uso de uma matriz de regularização ou o uso de solucionadores de gradiente nulo sem inversão.

A formulação obtida anteriormente (Eq. (22)) permanece válida. O fato de R poder ser igual a M não altera o arcabouço proposto, pois no máximo $\mathbf{I}_{M;R} = \mathbf{I}$ se $R = M$, e o gradiente continua sendo igual a $\mathbf{0}$.

Assumindo $R = M < N$, então todas as medições são linearmente independentes, e também é possível alcançar erro zero entre os tempos de trânsito modelados e medidos. Isso não necessariamente é um efeito desejado, pois pode levar ao sobreajuste do modelo aos dados, e a uma solução que não seja fisicamente coerente. Além disso, a independência linear das linhas de $\mathbf{R}_i$ (que ocorre se $R = M < N$) implica que

então $\mathbf{U}_{-R} = \mathbf{0}_{0 \times M}$ é um vetor vazio e, portanto, por meio de Eq. (25) temos $E(\mathbf{s}_{i+1}) = 0$. Isso significa que, se todas as medições forem linearmente independentes ($R = M$), é possível alcançar erro zero nos tempos medidos. Para medições linearmente dependentes, podem existir erros em caso de inconsistências nos valores medidos. Para a minimização ponderada, a independência linear nas linhas de $\mathbf{R}_i$ implica que a ponderação não afetará a minimização.

2 Pseudo-inversão pela Decomposição por Valores Singulares

Dado o passo de inversão necessário no problema mal-posto de TTT, uma possibilidade para lidar com esse obstáculo — como brevemente comentado — é o uso de uma pseudo-inversão baseada em DECOMPOSIÇÃO POR VALORES SINGULARES (SVD, do inglês *Singular Value Decomposition*) [16], para situações em que $\mathbf{R}_i$ é deficiente em posto.

Dada $\mathbf{R}_i$, podemos escrevê-la por meio de sua decomposição em valores singulares, como

$$\mathbf{R}_i = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^\top, \quad (20)$$

em que $\mathbf{U} \in \mathbb{R}^{M \times M}$ e $\mathbf{V} \in \mathbb{R}^{N \times N}$ são os vetores singulares à esquerda e à direita de $\mathbf{R}_i$, formando bases ortonormais; e $\mathbf{\Sigma} \in \mathbb{R}^{M \times N}$ é uma matriz diagonal não quadrada, cujas entradas diagonais $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_N$ são os valores singulares (estritamente não-negativos) de $\mathbf{R}_i$, em ordem decrescente. Por definição, $\mathbf{U}$, $\mathbf{\Sigma}$ e $\mathbf{V}$ dependem do iterador i , mas essa relação é omitida por clareza de notação.

2.1 Pseudo-inversa via SVD

Nós denotamos $R = \text{rank}(\mathbf{R}_i)$, e assumimos que $R < N$ (ou seja, $\mathbf{R}_i$ é uma matriz de posto deficiente). Nessa situação, apenas R dos valores singulares de $\mathbf{R}_i$ são não-nulos, e portanto então $\sigma_{R+1} = \dots = \sigma_N = 0$. Nesse cenário, a matriz $[\mathbf{R}_i^\top \mathbf{R}_i]^\dagger$ — onde $[\cdot]^\dagger$ denota a pseudo-inversa — pode ser obtida como

$$\begin{aligned} [\mathbf{R}_i^\top \mathbf{R}_i]^\dagger &= [\mathbf{V} \mathbf{\Sigma}^\top \mathbf{U}^\top \mathbf{U} \mathbf{\Sigma} \mathbf{V}^\top]^\dagger \\ &= [\mathbf{V} \mathbf{\Sigma}^\top \mathbf{\Sigma} \mathbf{V}^\top]^\dagger \\ &= \mathbf{V} [\mathbf{\Sigma}^\top \mathbf{\Sigma}]^\dagger \mathbf{V}^\top \\ &= \mathbf{V} \mathbf{\Sigma}^\dagger \mathbf{\Sigma}^{\top\dagger} \mathbf{V}^\top, \end{aligned} \quad (21)$$

onde foram utilizadas a ortogonalidade de $\mathbf{V}$ e a propriedade distributiva da pseudo-inversa (considerando a ortogonalidade de $\mathbf{V}$ e das colunas de $\mathbf{\Sigma}$); e $\mathbf{\Sigma}^\dagger \in \mathbb{R}^{N \times M}$ é a pseudo-inversa de $\mathbf{\Sigma}$, obtida diretamente como

a transposta de Σ com as entradas diagonais não nulas reciprocadas. Com essa pseudo-inversão de $\Sigma^\dagger$, e portanto de $\mathbf{R}_i^\top \mathbf{R}_i$, a solução para o problema de minimização é

$$\begin{aligned} \mathbf{G}_i &= \left[\mathbf{R}_i^\top \mathbf{R}_i \right]^\dagger \mathbf{R}_i^\top \\ &= \mathbf{V} \Sigma^\dagger \mathbf{U}^\top, \end{aligned} \quad (22)$$

que, pela definição da pseudo-inversa, leva a $\mathbf{G}_i = \mathbf{R}_i^\dagger$. Essa forma será usada, a menos que algebricamente necessário.

Função-custo

Com a solução $\mathbf{G}_i = \mathbf{R}_i^\dagger$, a solução do problema inverso é $\mathbf{s}_{i+1} = \mathbf{R}_i^\dagger \mathbf{t}_{\text{obs}}$; e disso, o gradiente é

$$\begin{aligned} \nabla E(\mathbf{s}_{i+1}) &= 2 \left(\mathbf{R}_i^\top \mathbf{R}_i \mathbf{R}_i^\dagger \mathbf{t}_{\text{obs}} - \mathbf{R}_i^\top \mathbf{t}_{\text{obs}} \right) \\ &= 2 \left(\mathbf{V} \Sigma^\top \mathbf{U}^\top \mathbf{U} \Sigma \mathbf{V}^\top \mathbf{V} \Sigma^\dagger \mathbf{U}^\top \mathbf{t}_{\text{obs}} - \mathbf{V} \Sigma^\top \mathbf{U}^\top \mathbf{t}_{\text{obs}} \right) \\ &= 2 \left(\mathbf{V} \Sigma^\top \Sigma \Sigma^\dagger \mathbf{U}^\top \mathbf{t}_{\text{obs}} - \mathbf{V} \Sigma^\top \mathbf{U}^\top \mathbf{t}_{\text{obs}} \right) \\ &= 2 \left(\mathbf{V} \Sigma^\top [\mathbf{I}_{M;R} - \mathbf{I}_M] \mathbf{U}^\top \mathbf{t}_{\text{obs}} \right) \end{aligned} \quad (23)$$

onde $\mathbf{I}_{M;R} \in \mathbb{R}^{M \times M}$ é uma matriz diagonal cujas primeiras R entradas são 1, e as $M - R$ restantes são 0; e $\mathbf{I}_M \in \mathbb{R}^{M \times M}$ é a matriz identidade. Portanto, $\mathbf{I}_{M;R} - \mathbf{I}_M$ possui suas primeiras R entradas diagonais iguais a 0, e as últimas $M - R$ entradas iguais a -1 . Como todas as linhas de $\Sigma^\top$ pertencem ao espaço-nulo de $\mathbf{I}_{M;R} - \mathbf{I}_M$ (apenas as primeiras R entradas de qualquer linha de $\Sigma^\top$ são não-nulas, exatamente onde $\mathbf{I}_{M;R} - \mathbf{I}_M$ é zero), então $\Sigma^\top [\mathbf{I}_{M;R} - \mathbf{I}_M] = \mathbf{0}$. Portanto,

$$\begin{aligned} \nabla E(\mathbf{R}_i^\dagger \mathbf{t}_{\text{obs}}) &= 2 \left(\mathbf{V} \mathbf{0} \mathbf{U}^\top \mathbf{t}_{\text{obs}} \right) \\ &= \mathbf{0} \end{aligned} \quad (24)$$

Essa verificação garante que $\mathbf{s}_{i+1} = \mathbf{R}_i^\dagger \mathbf{t}_{\text{obs}}$ é uma solução para o processo de minimização da Eq. (7); esse resultado é importante, garantindo que a otimização do problema inverso opere corretamente.

Gradiente

Denotamos $\mathbf{U}_k$ como as primeiras k colunas de $\mathbf{U}$, $\mathbf{U}_{-k}$ como as últimas k colunas de $\mathbf{U}$, e $\mathbf{U}_{(j \sim k)}$ como as colunas de j até k (inclusive) de $\mathbf{U}$. Utilizando essa notação, a função-custo residual para a solução com a Eq. (22) pode ser obtida explicitamente, sendo dada por

$$E(\mathbf{s}_{i+1}) = \mathbf{t}_{\text{obs}}^\top \mathbf{U}_{-R} \mathbf{U}_{-R}^\top \mathbf{t}_{\text{obs}} \quad (25)$$

2.2 Usando o espaço-nulo

Podemos expandir a solução $\mathbf{s}_{i+1} = \mathbf{R}_i^\dagger \mathbf{t}_{\text{obs}}$ explorando o espaço-nulo de $\mathbf{R}_i$. Escrevemos

$$\mathbf{V} = \left[\mathbf{V}_1 \mid \mathbf{V}_2 \right] \quad (26)$$

onde $\mathbf{V}_1 \in \mathbb{R}^{N \times R}$ são as primeiras R colunas de $\mathbf{V}$ (correspondentes aos valores singulares não-nulos), e $\mathbf{V}_2 \in \mathbb{R}^{N \times (N-R)}$ são as $N - R$ colunas restantes de $\mathbf{V}$ (correspondentes aos valores singulares nulos); $[\cdot \mid \cdot]$ denota concatenação de matrizes. Como $\mathbf{V}_2$ está associado aos valores singulares nulos de $\mathbf{R}_i$, isso implica que as colunas de $\mathbf{V}_2$ formam uma base ortonormal para o nul ($\mathbf{R}_i$).

Seja $\boldsymbol{\mu} \in \mathbb{R}^{(N-R) \times 1}$ um vetor de coordenadas. Nesse caso, qualquer $\bar{\mathbf{s}} = \mathbf{V}_2 \boldsymbol{\mu}$ estará dentro do espaço-nulo de $\mathbf{R}_i$; e portanto $\mathbf{R}_i \bar{\mathbf{s}} = \mathbf{U} \Sigma \mathbf{V}^\top \mathbf{V}_2 \boldsymbol{\mu} = \mathbf{0}$ (pela ortogonalidade de $\mathbf{V}$, e pelas colunas nulas de Σ). Isso significa que, para $\mathbf{s}_{i+1} \equiv \mathbf{s}_{i+1}(\boldsymbol{\mu}) = \mathbf{R}_i^\dagger \mathbf{t}_{\text{obs}} + \mathbf{V}_2 \boldsymbol{\mu}$, temos

$$E(\mathbf{R}_i^\dagger \mathbf{t}_{\text{obs}} + \mathbf{V}_2 \boldsymbol{\mu}) = E(\mathbf{R}_i^\dagger \mathbf{t}_{\text{obs}}) \quad (27a)$$

$$\nabla E(\mathbf{R}_i^\dagger \mathbf{t}_{\text{obs}} + \mathbf{V}_2 \boldsymbol{\mu}) = \mathbf{0} \quad (27b)$$

Ou seja, a função-custo $E(\mathbf{s}_{i+1}(\boldsymbol{\mu}))$ e seu gradiente são invariantes em relação a $\boldsymbol{\mu}$. Podemos usar essa informação para modificar a solução encontrada, explorando o espaço-nulo de $\mathbf{R}_i$, e buscando uma solução que atenda algum outro critério.

2.3 Minimização de métrica secundária

Dada uma solução para a minimização da Eq. (3), que pela Eq. (22) terá a forma $\mathbf{R}_i^\dagger \mathbf{t}_{\text{obs}}$, definimos $F(\boldsymbol{\mu})$ como uma função custo secundária em função de $\boldsymbol{\mu}$, da forma

$$F(\boldsymbol{\mu}) = \left\| \mathbf{D} \left(\mathbf{R}_i^\dagger \mathbf{t}_{\text{obs}} + \mathbf{V}_2 \boldsymbol{\mu} \right) \right\|^2 \quad (28)$$

onde $\mathbf{D}$ é a matriz que governa essa métrica secundária (semelhante à Seção 1.3).

Dado que a ortogonalidade das colunas de $\mathbf{V}_2$ implica $\text{rank}(\mathbf{V}_2) = N - R$ (o que significa que $\mathbf{V}_2$ é de posto completo), e assumindo que $\mathbf{D}$ também é uma matriz de posto completo, uma solução para esse problema pode ser encontrada diretamente, da forma

$$\boldsymbol{\mu} = - \left[\mathbf{V}_2^\top \mathbf{D}^\top \mathbf{D} \mathbf{V}_2 \right]^{-1} \mathbf{V}_2^\top \mathbf{D}^\top \mathbf{D} \mathbf{R}_i^\dagger \mathbf{t}_{\text{obs}} \quad (29)$$

Por propriedades da pseudo-inversa, isso pode ser escrito como

$$\boldsymbol{\mu} = - [\mathbf{D} \mathbf{V}_2]^\dagger \mathbf{D} \mathbf{R}_i^\dagger \mathbf{t}_{\text{obs}} \quad (30)$$

Com isso, a solução completa para ambos — minimizando o erro quadrático de tempo de viagem da Eq. (3) e a métrica de regularização da Eq. (28) — será

$$\begin{aligned} \mathbf{s}_{i+1} &= \mathbf{R}_i^\dagger \mathbf{t}_{\text{obs}} - \mathbf{V}_2 [\mathbf{D} \mathbf{V}_2]^\dagger \mathbf{D} \mathbf{R}_i^\dagger \mathbf{t}_{\text{obs}} \\ &= \left(\mathbf{I}_N - \mathbf{V}_2 [\mathbf{D} \mathbf{V}_2]^\dagger \mathbf{D} \right) \mathbf{R}_i^\dagger \mathbf{t}_{\text{obs}} \end{aligned} \quad (31)$$

Essa solução possui gradiente nulo na função-custo primária (Seção 2.2) e minimiza a função-custo secundária dentro do espaço de soluções de erro mínimo da função primária. A principal ideia por trás dessa expansão com $\boldsymbol{\mu}$ é que, ao explorar o espaço-nulo de $\mathbf{R}$, minimizamos o objetivo primário no espaço-linha e o secundário no espaço-nulo. Note que esse procedimento só funciona se $\text{rank}(\mathbf{R}_i) = R < N$. Se $R = N$, não há espaço-nulo a ser explorado e a segunda minimização não pode ser realizada.

Outra observação importante nesse cenário é que $\mathbf{V}_2 [\mathbf{D} \mathbf{V}_2]^\dagger \mathbf{D}$ não pode ser simplificado. Isso exigiria que $\mathbf{V}_2$ tivesse linhas linearmente independentes, o que não é possível dado que $N > N - R$, e que $\mathbf{V}_2 \in \mathbb{R}^{N \times N - R}$.

2.4 Truncamento da SVD

Nas Seções 2.2 e 2.3, $\mathbf{V}_2$ foi construído como as colunas de $\mathbf{V}$ correspondentes ao espaço-nulo de $\mathbf{V}$; e, de forma equivalente, os valores singulares nulos de $\boldsymbol{\Sigma}$.

Assumamos que, das R entradas diagonais não-nulas de $\boldsymbol{\Sigma}$, apenas $\tilde{R}$ são relevantes; ou seja, $R - \tilde{R}$ das entradas não-nulas são tão pequenas que podem ser desprezadas. Efetivamente, isso é equivalente a truncar $\boldsymbol{\Sigma}$, eliminando (forçando como zero) as $R - \tilde{R}$ menores entradas não-nulas. Definimos $\tilde{\boldsymbol{\Sigma}}$ como essa versão truncada de $\boldsymbol{\Sigma}$.

Esse truncamento serve duas funções: ele reduz o número de condicionamento efetivo (razão entre os maior e menor valores singulares não-nulos), consequentemente melhorando a estabilidade no problema de inversão da minimização da métrica primária; e aumenta o espaço-nulo prático a ser explorado na otimização secundária, permitindo que a métrica secundária seja minimizada de forma mais agressiva. Em contrapartida, esse truncamento introduzirá algum erro na minimização primária, fazendo com que o mínimo encontrado não possua gradiente nulo.

Com esse truncamento, é fácil ver que a solução para a Eq. (22) será

$$\begin{aligned}\mathbf{G}(\mathbf{s}_i) &\approx \tilde{\mathbf{G}}(\mathbf{s}_i) \\ &= \mathbf{V}\tilde{\boldsymbol{\Sigma}}^\dagger \mathbf{U}^\top\end{aligned}\quad (32)$$

Usando que os valores singulares de $\boldsymbol{\Sigma}$ estão dispostos em ordem decrescente, o gradiente para uma solução usando esse $\tilde{\mathbf{G}}_i$ é

$$\nabla E(\mathbf{s}_{i+1}) = 2 \left(\sum_{i=\tilde{R}+1}^R \sigma_i \mathbf{v}_i \mathbf{u}_i^\top \right) \mathbf{t}_{\text{obs}} \quad (33)$$

onde $\mathbf{v}_i$ e $\mathbf{u}_i$ são a i -ésima linha de $\mathbf{V}$ e $\mathbf{U}$, respectivamente, e σ_i é o i -ésimo elemento diagonal de $\boldsymbol{\Sigma}$. Quanto menores forem as entradas de $\boldsymbol{\Sigma}$ que foram definidas como zero (σ_i para $i \in [\tilde{R} + 1, R]$), menor será o gradiente, e mais próxima a solução obtida estará do espaço de soluções ótimas ($\nabla E = 0$).

Com a formulação anterior, a função-custo com a SVD truncada será

$$E(\mathbf{s}_{i+1}) = \mathbf{t}_{\text{obs}}^\top \mathbf{U}_{-\tilde{R}} \mathbf{U}_{-\tilde{R}}^\top \mathbf{t}_{\text{obs}} \quad (34)$$

ou ainda, a variação na função-custo, comparada àquela sem valores singulares truncados, é dada por

$$\Delta E(\mathbf{s}_{i+1}) = \mathbf{t}_{\text{obs}}^\top \mathbf{U}_{\tilde{R}\sim R} \mathbf{U}_{\tilde{R}\sim R}^\top \mathbf{t}_{\text{obs}} \quad (35)$$

onde as colunas de $\mathbf{U}_{\tilde{R}\sim R}$ são exatamente as colunas correspondentes aos valores singulares truncados.

Note que esse erro ΔE é independente dos valores singulares truncados. Portanto, a escolha dos σ a serem truncados não está relacionada ao aumento da função-custo. A escolha de quais valores singulares truncar determinará a matriz $\mathbf{U}_{\tilde{R}\sim R}$ que define ΔE , mas as magnitudes dos valores singulares não são relevantes.

3 Resultados para TTT tradicional e SVD

Para comparar as duas técnicas apresentadas (TTT pelo modelo-padrão com regularização e normalização, e SVD com regularização), ambas serão implementadas para as mesmas situações.

3.1 Ambiente

Foram utilizados dados do World Ocean Atlas (WOA) [17] de temperatura, pressão, e salinidade, aliados à biblioteca GSW em Python [18], para construir SSPs para cada coluna d'água de medições/estimativas dos parâmetros. A partir desses dados, foi selecionado um recorte próximo ao sul do Brasil (próximo a -36.5°S , -50.5°W), de onde foram extraídos $N_x = 9$ perfis, e assumiu-se que o SSF fosse uma concatenação 2D desses perfis. Esses perfis são referentes aos valores anuais do WOA (não necessariamente uma média anual), e foram limitados a $z = 1500\text{m}$ com um *downsampling* de 2 vezes; ou seja, o SSF é estratificado em $N_z = 31$ camadas.

3.2 Distribuição de dispositivos

Serão utilizadas duas distribuições de dispositivos, com propósitos distintos. Em ambas, há 9 fontes, e 9 receptores.

Todo entorno

A primeira distribuição segue o que é mais comumente visto na literatura (conforme os artigos apresentados na revisão bibliográfica [1]), em que os dispositivos (fontes e receptores) estão alocados em todo o entorno do ambiente sendo modelado. Embora geralmente seja tomado que todos os dispositivos são simultaneamente fonte e receptor, assumiremos que cada um cumpre um papel distinto.




Figura 1: SSF discreto.




Figura 2: Perfis do SSF, para cada coluna d'água.

Aqui, as fontes estarão no solo (4 fontes, $z = 1500\text{m}$, x variando) e à direita (5 fontes, $x = 1500\text{m}$, z variando); e os receptores estarão na superfície (4 receptores, $z = 0\text{m}$, x variando) e à esquerda (5 receptores, $x = 0\text{m}$, z variando).

Essa condição emula uma situação em que há o máximo de informação espacial disponível, com ondas viajando em todas as direções.

Camadas

A segunda distribuição é mais alinhada com as limitações do projeto [1]; ou seja, as fontes estão localizadas exclusivamente no solo (9 fontes, $z = 1500\text{m}$, x variando), e os receptores exclusivamente na superfície (9 receptores, $z = 0\text{m}$, x variando).

Essa condição é mais próxima às limitações impostas pelo projeto e pelos dispositivos disponíveis, e portanto mais alinhada ao desejado de implementação dos métodos.

3.3 Métricas e avaliação

Para comparar os resultados entre as duas técnicas, para as diferentes distribuições de dispositivos apresentadas, serão utilizadas algumas métricas objetivas, primariamente tratando do erro para o resultado obtido.

Erro de tempo de trânsito

A primeira métrica reflete o erro de tempo de trânsito entre os SSFs verdadeiro e estimado. Denotamos $\text{RMSE}_t(\mathbf{s})$ como o erro quadrático médio de tempo de trânsito (RMS error ou RMSE) entre os tempos de percurso verdadeiro e estimado, dado por

$$\begin{aligned} \text{RMSE}_t(\mathbf{s}_{\text{est}}) &= \frac{1}{M} \sqrt{E(\mathbf{s}_{\text{est}})} \\ &= \frac{1}{M} \|\mathbf{R}_{\text{est}}\mathbf{s}_{\text{est}} - \mathbf{t}_{\text{true}}\| \end{aligned} \quad (36)$$

em que $\mathbf{s}_{\text{est}}$ é o campo de vagariedade obtido ao final do processo de estimação, e $\mathbf{R}_{\text{est}}$ é a matriz de distâncias relacionada a ele.

Essa métrica permite comparar os modelos estimados com o resultado observado por meio da métrica objetiva que está sendo otimizada primariamente.

Erro RMS de SSF

Além do erro RMS de tempo de trânsito, também utilizaremos o erro RMS entre os campos de velocidade verdadeiro $\mathbf{c}_{\text{true}}$ e o estimado $\mathbf{c}_{\text{est}} = 1/\mathbf{s}_{\text{est}}$,

$$\text{RMSE}_{\text{ssf}}(\mathbf{s}_{\text{est}}) = \frac{1}{M} \|\mathbf{c}_{\text{true}} - \mathbf{c}_{\text{est}}\| \quad (37)$$

novamente com $\mathbf{s}_{\text{est}}$ sendo o campo de vagarosidade obtido ao final do processo de estimação. Essa métrica permite comparar os resultados do objetivo real da otimização — esse sendo a estimação do SSF real.

Embora a variável de modelo $\mathbf{s}$ represente a vagarosidade sonora no ambiente, as figuras e discussões serão feitas em termos da velocidade do som. Dada a relação inversa entre essas grandezas, essa escolha não implica em perda de informação, apenas auxiliando na visualização e apresentação.

3.4 Processo de estimação

Aqui serão apresentados os dados necessários para a estimação. Por simplicidade, o método-padrão usando TTT apresentado na Seção 1 será chamado de método TTT; e o método apresentado utilizando SVD truncada mostrado na Seção 2 será chamado de método SVD.

Solução do problema direto

O pacote Python `EikonalFM` [19] será utilizado, implementando o FMM [20, 21] para resolver os tempos de primeira chegada ao longo dos pontos da grade. Isso está alinhado com a abordagem padrão adotada na literatura para estimar $\mathbf{R}_i$ em cada iteração, dado o vetor de vagarosidades $\mathbf{s}_i$.

Parâmetros

Para cada uma das distribuições especificadas na Seção 3.2, os parâmetros da regularização para os dois métodos (TTT e SVD) será diferente. Além disso, enquanto matematicamente o método SVD foi definido em relação a um $\hat{R}$, aqui será usado um parâmetro α , e serão truncados os valores singulares σ_n tal que $\sigma_n < 0.5\sigma_0$; ou seja, o truncamento é proporcional ao maior valor singular.

Para a distribuição no entorno, o método TTT usará $\alpha = 3.51$, e o método SVD utilizará $\alpha = 0.2622$. Já para a distribuição em camadas, o método TTT usará $\alpha = 7.02$, e o método SVD utilizará $\alpha = 0.6735$.

Regularização

Será usada uma regularização que aproxime discretamente o Laplaciano. Essa regularização tem o objetivo de suavizar o SSF estimado, levando a um campo mais regular e polido. Para essa regularização, a matriz D é definida por blocos

$$\mathbf{D} = \begin{bmatrix} \mathbf{Q}' & \mathbf{I}_{N_x} & \mathbf{0} & \cdots & \mathbf{0} \\ \mathbf{I}_{N_x} & \mathbf{Q} & \mathbf{I}_{N_x} & \cdots & \mathbf{0} \\ \mathbf{0} & \mathbf{I}_{N_x} & \mathbf{Q} & \cdots & \mathbf{0} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \mathbf{0} & \mathbf{0} & \mathbf{0} & \cdots & \mathbf{Q}' \end{bmatrix} \quad (38)$$

onde $\mathbf{Q}, \mathbf{Q}' \in \mathbb{R}^{N_x \times N_x}$ são matrizes de bloco dadas por

$$\mathbf{Q}' = \begin{bmatrix} -2 & 1 & 0 & \cdots & 0 & 0 \\ 1 & -3 & 1 & \cdots & 0 & 0 \\ 0 & 1 & -3 & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & -3 & 1 \\ 0 & 0 & 0 & \cdots & 1 & -2 \end{bmatrix} \quad (39a)$$

$$\mathbf{Q} = \mathbf{Q}' - \mathbf{I}_{N_x} \quad (39b)$$




Figura 3: Evolução dos erros RMS do processo de estimação do SSF, para os métodos TTT e SVD, nos cenários de dispositivos no perímetro e em camadas, ao longo de 10 iterações.

3.5 Resultados e discussão

A Fig. 3 mostra os erros RMS de tempo de trânsito (Fig. 3a) e do SSF estimado (Fig. 3b), para cada iteração. Note que em ambas as figuras, o eixo y está em escala logarítmica.

Em ambas as figuras, tem 2 comportamentos que podem ser vistos:

Comparação entre distribuições

Comparando os desempenhos, ambos os dois métodos tiveram performance semelhantes no caso no entorno, e esse sendo estritamente superior (para o erro de SSF) em relação ao caso em camadas. Além disso, enquanto o SVD em camadas teve uma performance aceitável e constante de $RMSE_t$ (mas não de $RMSE_{ssf}$), o resultado da TTT deteriorou com o passar das iterações, para ambas as métricas. Isso indica um descasamento entre os problemas direto e inverso, levando a um processo de minimização disfuncional.

Esses comportamentos estão relacionados à distribuição dos dispositivos: com os dispositivos no entorno, os raios atravessam o meio em direções diferentes, gerando uma maior quantidade de informação espacial sobre o ambiente, e portanto permitindo uma estimação melhor do SSF. Por outro lado, com os dispositivos em camadas próximas ao solo e à superfície, não há informação espacial o suficiente, levando a *overfitting* sobre os dados, podendo até causar piora com a minimização (como no caso da TTT).

Perfis estimados

Por abrangência, a Fig. 4 mostra, para cada método + distribuição, o erro do SSF estimado em relação ao perfil real (conforme a Fig. 1), ao longo da profundidade (no eixo y).

Note que as Figs. 4a e 4b referem-se à distribuição no entorno, e nelas o eixo x se estende no intervalo $[-6, 3]$; enquanto as Figs. 4c e 4d referem-se à distribuição em camadas, e o eixo x se estende no intervalo $[-60, 30]$. Além disso, comparando os perfis que se desenham em cada distribuição, nota-se que o erro para os dispositivos no entorno é próximo a zero e com um comportamento quase aleatório; e para os dispositivos no entorno o erro é consistente e com um comportamento característico, que se comparado aos perfis da Fig. 2, revela que o SSF é quase uniforme, para esse caso.




Figura 4: Erros de estimação de cada SSP, para os métodos TTT e SVD, nos cenários de dispositivos no perímetro e em camadas, para a iteração final.

Discussão

Como visto pelos resultados na distribuição no entorno, ambos os métodos são capazes de alcançar um desempenho bom de estimação do SSF (com erro médio de 1m/s ou menos). Por outro lado, os resultados com a distribuição em camadas — essa sendo a distribuição de interesse para o projeto, como já previamente discutido — revelam que nenhuma das duas técnicas é capaz de alcançar resultados razoáveis, com erros absolutos de até 60m/s, e erro médio de mais de 20m/s.

Isso indica que nenhuma das duas técnicas é suficiente para conseguir inverter o SSF para o caso de dispositivos em camadas, e portanto outras técnicas — que utilizem outras informações adquiridas nos receptores, ou informações *a priori* — precisariam ser empregadas.

4 Mtodos adaptados da TTT

Como visto na seo anterior, nenhum dos mtodos apresentados alcanou resultados satisfatrios na estimaco do SSF, na situao de interesse/relevncia para o projeto. Disso, ser necessrio desenvolver um mtodo diferente, que seja capaz de obter resultado melhores.

Pela simplicidade matemtica e por os resultados serem muito semelhantes, aqui ser usado como base o modelo-padro TTT como desenvolvido na Seo 1, a partir do qual sero desenvolvidos dois novos mtodos, que utilizem informaes *a priori* novas.

4.1 Comportamento profundo

Conforme mostrado nos trabalhos de Munk et al. [22] e Possenti et al. [23], o comportamento global do SSF converge conforme a profundidade aumenta, com variaes pequenas prximas ao SOFAR (profundidade de 1000m), e imperceptveis para profundidades abaixo de 2000m.

Essa informao pode ser utilizada na modelagem, determinando um comportamento esperado a partir de determinada profundidade, o que pode ser includo no problema como uma segunda regularizao.

Perfil de Munk

O PERFIL DE MUNK [24]  um perfil terico que descreve aproximadamente o comportamento da velocidade do som na gua em oceanos, variando exclusivamente com a profundidade. Por ser um modelo terico, ele simplifica muitos dos efeitos e das nuances que podem ocorrer, e serve primariamente como um guia. Ele  descrito por

$$v(z) = V_0 \left(1 + \epsilon_0 \left[e^{2 \frac{z-z_0}{B_0}} + 2 \frac{z-z_0}{B_0} - 1 \right] \right) \quad (40)$$

em que $V_0 = 1500\text{m/s}$, $\epsilon_0 = 0.00737$, $z_0 = 1300\text{m}$, e $B_0 = 1300\text{m}$ so os parmetros que controlam o perfil de Munk. Os valores apresentados so os mais comumente utilizados na literatura, e podem variar em casos especficos.

 possvel modificar a formulao da TTT alcanada na Seo 1 para incluir (de alguma forma) a informao de um perfil-referncia, como o perfil de Munk apresentado, ou algum outro perfil obtido previamente. Sero apresentados dois perfis que utilizem essa informao *a priori*.

4.2 Mtodo em camadas separadas

Nesse mtodo, ns separamos o SSF em duas camadas: at uma profundidade-limite z_{lim} (que, sem perda de generalidade, assumiremos $z_{\text{lim}} = 1000\text{m}$) o SSF ser modelado atravs de otimizao por minimizao da funo custo; e abaixo dessa profundidade, o SSF ser tomado como sendo conhecido (pelo perfil *a priori*) e no precisa ser estimado.

Matematicamente, assumimos que o SSF $\mathbf{s}_i$ pode ser separado em dois vetores, $\mathbf{s}_1$ e $\mathbf{s}_2$. Sem perda de generalidade, assume-se que

$$\mathbf{s}_{i+1} = [\mathbf{s}_1^T | \mathbf{s}_2^T]^T \quad (41)$$

com $[\cdot | \cdot]$ sendo concatenao vetorial; omite-se a dependncia de $\mathbf{s}_1$ e $\mathbf{s}_2$ em i por clareza. Disso, e tomando a funo-custo regularizada da Eq. (7) com regularizao quadrtica, atravs de manipulaes algbricas chega-se a

$$\begin{aligned} E(\mathbf{s}_1) = & \mathbf{s}_1^T \mathbf{R}_{i,1}^T \mathbf{R}_{i,1} \mathbf{s}_1 + \mathbf{s}_1^T \mathbf{R}_{i,1}^T (\mathbf{R}_{i,2} \mathbf{s}_2 - \mathbf{t}_{\text{obs}}) + (\mathbf{R}_{i,2} \mathbf{s}_2 - \mathbf{t}_{\text{obs}})^T \mathbf{R}_{i,1} \mathbf{s}_1 + \|\mathbf{R}_{i,2} \mathbf{s}_2 - \mathbf{t}_{\text{obs}}\|^2 \\ & + \alpha^2 \left(\mathbf{s}_1^T \mathbf{D}_{i,1}^T \mathbf{D}_{i,1} \mathbf{s}_1 + \mathbf{s}_1^T \mathbf{D}_{i,1}^T \mathbf{D}_{i,2} \mathbf{s}_2 + \mathbf{s}_2^T \mathbf{D}_{i,2}^T \mathbf{D}_{i,1} \mathbf{s}_1 + \mathbf{s}_2^T \mathbf{D}_{i,2}^T \mathbf{D}_{i,2} \mathbf{s}_2 \right) \end{aligned} \quad (42)$$

onde $\mathbf{R}_{i,1}$ compreende as colunas iniciais de $\mathbf{R}_i$ correspondentes a $\mathbf{s}_1$, e $\mathbf{R}_2$ as colunas finais correspondentes a $\mathbf{s}_2$. O mnimo dessa funo-custo  obtido com $\mathbf{s}_{i+1;s}^*$, dado por

$$\mathbf{s}_{i+1;s}^* = \left[\mathbf{R}_{i,1}^T \mathbf{R}_{i,1} + \alpha^2 \mathbf{D}_1^T \mathbf{D}_1 \right]^{-1} \left(\mathbf{R}_{i,1}^T \mathbf{t}_{\text{obs}} - \mathbf{R}_{i,1}^T \mathbf{R}_{i,2} \mathbf{s}_2 - \alpha^2 \mathbf{D}_1^T \mathbf{D}_2^T \mathbf{s}_2 \right) \quad (43)$$

em que o subscrito s de $\mathbf{s}_{i+1,s}^*$ identifica que esse é o mínimo para o caso de camadas separadas.

É possível comparar esse resultado com a solução para o TTT regularizado base da Eq. (8). Tem-se que o termo inverso (em colchetes) é quase idêntico, com a única diferença sendo que aqui ele considera somente a camada a ser invertida. O outro termo (em parênteses) possui elementos adicionais: especificamente, o termo $\mathbf{R}_{i,1}^\top \mathbf{R}_{i,2} \mathbf{s}_2$ está relacionado ao tempo de trânsito na camada conhecida (abaixo de z_{lim}); e o termo $\alpha^2 \mathbf{D}_1^\top \mathbf{D}_2^\top \mathbf{s}_2$ à suavidade entre as camadas estimada e a determinada *a priori* (pelo perfil de Munk, ou algum outro meio).

Embora nesse método a vagariedade só precisa ser estimada pra a parte superior no problema inverso, o solver Eikonal ainda precisa determinar as distâncias percorridas em todas as células, pois a solução $\mathbf{s}_{i+1,s}^*$ ainda depende de $\mathbf{R}_2$, e esse pode mudar dependendo da solução anterior.

4.3 Método *trade-off*

Enquanto no método anterior a informação *a priori* da região mais profunda era integrada de uma maneira impositiva à modelagem e à função custo, aqui será tomada uma abordagem mais suave; ou seja, ao invés de forçar que a velocidade é um valor conhecido, esse valor conhecido será usado como guia para as células abaixo de z_{lim} .

Isso pode ser traduzido matematicamente como uma regularização extra na função-custo definida na Eq. (8), agora escrita como

$$E(\mathbf{s}_{i+1}) = \|\mathbf{R}_i \mathbf{s}_{i+1} - \mathbf{t}_{\text{obs}}\|^2 + \alpha^2 \|\mathbf{D} \mathbf{s}_{i+1}\|^2 + \beta^2 \|\mathcal{I}(\mathbf{s}_{i+1} - \mathbf{s}_{\text{obs}})\|^2 \quad (44)$$

onde β é um parâmetro de regularização para esse segundo termo; $\mathcal{I} \in \mathbb{R}^{N \times N}$ denota uma matriz diagonal, cujo i -ésimo elemento diagonal é 1 se a célula correspondente (elemento de $\mathbf{s}$) está abaixo de z_{lim} , e 0 caso contrário; e $\mathbf{s}_{\text{obs}}$ é a velocidade do som referência. O mínimo dessa função-custo é obtido com $\mathbf{s}_{i+1;t}^*$,

$$\mathbf{s}_{i+1;t}^* = \left[\mathbf{R}_i^\top \mathbf{R}_i + \alpha^2 \mathbf{D}^\top \mathbf{D} + \beta^2 \mathcal{I}^\top \mathcal{I} \right]^{-1} \left(\mathbf{R}_i^\top \mathbf{t}_{\text{obs}} + \beta^2 \mathcal{I}^\top \mathcal{I} \mathbf{s}_{\text{obs}} \right) \quad (45)$$

com o subscrito t identificando que esse é o mínimo pelo método *trade-off*.

Note que apenas $\mathbf{R}_i$ depende da iteração anterior, enquanto as demais variáveis são constantes de modelagem ($\mathbf{D}$ e $\mathcal{I}$), observações ($\mathbf{t}_{\text{obs}}$ obtido nos levantamentos, e $\mathbf{s}_{\text{obs}}$ de dados ambientais ou expedições anteriores), ou parâmetros ajustáveis (α e β). Um α maior favorece um ambiente menos variável, trocando acurácia por suavidade; enquanto um β maior força o perfil de lentidão a aproximar-se mais da referência $\mathbf{s}_{\text{obs}}$.

4.4 Formas normalizadas

Da mesma forma que a formulação tradicional da TTT foi normalizada (de forma a aumentar a robustez da otimização à magnitude do ambiente), as duas formulações desenvolvidas aqui também podem. Em particular, novamente toma-se $\rho = \|\mathbf{R}_i\|_F$, $\delta = \|\mathbf{D}\|_F$, e agora denota-se $\iota = \|\mathcal{I}\|_F$. Com isso, as novas soluções (normalizadas) são

$$\mathbf{s}_{i+1;s}^*(\alpha) = \left[\dot{\mathbf{R}}_{i,1}^\top \dot{\mathbf{R}}_{i,1} + \alpha^2 \dot{\mathbf{D}}_1^\top \dot{\mathbf{D}}_1 \right]^{-1} \left(\frac{1}{\rho} \dot{\mathbf{R}}_{i,1}^\top \mathbf{t}_{\text{obs}} - \dot{\mathbf{R}}_{i,1}^\top \dot{\mathbf{R}}_{i,2} \mathbf{s}_2 - \alpha^2 \dot{\mathbf{D}}_1^\top \dot{\mathbf{D}}_2 \mathbf{s}_2 \right) \quad (46)$$

para o método em camadas separadas, e

$$\mathbf{s}_{i+1;t}^*(\alpha, \beta) = \left[\dot{\mathbf{R}}_i^\top \dot{\mathbf{R}}_i + \alpha^2 \dot{\mathbf{D}}^\top \dot{\mathbf{D}} + \beta^2 \dot{\mathcal{I}}^\top \dot{\mathcal{I}} \right]^{-1} \left(\frac{1}{\rho} \dot{\mathbf{R}}_i^\top \mathbf{t}_{\text{obs}} + \beta^2 \dot{\mathcal{I}}^\top \dot{\mathcal{I}} \mathbf{s}_{\text{obs}} \right) \quad (47)$$

para o método *trade-off*. Para o mesmo resultado, α será diferente, contudo por esse ser um parâmetro arbitrário, ele foi mantido. As novas matrizes normalizadas são $\dot{\mathbf{R}}_i = \frac{\mathbf{R}_i}{\rho}$ (com $\dot{\mathbf{R}}_{i,1}$ e $\dot{\mathbf{R}}_{i,2}$ construídas da mesma forma que anteriormente), $\dot{\mathbf{D}} = \frac{\mathbf{D}}{\delta}$, e $\dot{\mathcal{I}} = \frac{\mathcal{I}}{\iota}$.

Aqui a dependência dos vetores de vagariedade em relação aos parâmetros α e β foi explicitada.

Intercalao entre mtodos

Por padronizao, denotamos a soluo do TTT tradicional como

$$\mathbf{s}_{i+1;b}^*(\alpha) = \frac{1}{\rho} \left[\dot{\mathbf{R}}_i^\top \dot{\mathbf{R}}_i + \alpha^2 \dot{\mathbf{D}}^\top \dot{\mathbf{D}} \right]^{-1} \dot{\mathbf{R}}_i^\top \mathbf{t}_{\text{obs}} \quad (48)$$

com o subscrito b denotando essa ser a soluo “bsica”. Com essas soluoes (Eqs. (46) a (48)),   possvel mostrar que

$$\mathbf{s}_{i+1;t}^*(\alpha, 0) = \mathbf{s}_{i+1;b}^*(\alpha) \quad (49)$$

$$\mathbf{s}_{i+1;t}^*(\alpha, \infty) = \mathbf{s}_{i+1;s}^*(\alpha) \quad (50)$$

Ou seja, o mtodo de *trade-off* interpola entre o mtodo TTT tradicional (da Eq. (11)), e o mtodo de camadas separadas, dependendo do valor do parmetro β . Um valor intermedirio desse parmetro resultar em uma “soluo intermediria” entre os outros dois (bsico e separado).

5 Mtodos alternativos de estimaco do SSF com tempo de trnsito

At o momento, foram tratados mtodos para estimaco do SSF que ou so a *Travel-Time Tomography* tradicional (Seoo 1), ou so modificaoes pequenas em cima da TTT tradicional, incluindo informaoes diferentes (Seoo 4), ou com um mtodo diferente para o passo da inverso (Seoo 2).

Dado isso,  possvel utilizar a estrutura da TTT (de minimizao do erro de tempo de trnsito entre o modelo e o resultado), e ali-la a outras ferramentas de modelagem, de forma a obter um resultado que mais proximamente se alinhe ao SSF real. Isso foi tentado atravs da SVD anteriormente (Seoo 2), mas como mostrado na Seoo 3 isso no foi suficiente para alcanar resultados satisfatrios na situao em camadas; essa sendo a mais alinhada com imposioes prticas.

5.1 Mtodo por parametrizao de Munk

O primeiro mtodo  uma adaptao do proposto por Wu et al. [25], expandindo-o para o caso multi-dimensional, e com uma escolha de parmetros levemente modificada.

Para esse mtodo, retornaremos ao perfil de Munk da Eq. (40). Consideraremos um ambiente bidimensional (sem perda de generalidade), com $N_z \times N_x$ clulas. Cada coluna de clulas (com posio x) ser regida por um perfil de Munk diferente, com parmetros v_x , ϵ_x , z_x , e B_x ; e, disso, pela Eq. (40),

$$v(x, z) = V_x \left(1 + \epsilon_x \left[e^{2 \frac{z - z_x}{B_x}} + 2 \frac{z - z_x}{B_x} - 1 \right] \right) \quad (51)$$

Denota-se $\mathbf{V}, \boldsymbol{\epsilon}, \mathbf{z}, \mathbf{B} \in \mathbb{R}^{N_x \times 1}$ como vetores dos parmetros de Munk, e $\boldsymbol{\beta} \in \mathbb{R}^{4N_x \times 1}$ como um vetor de parmetros, contemplando todos os $4N_x$ parmetros de modelagem, dado por

$$\boldsymbol{\beta} = \left[\mathbf{V}^\top \boldsymbol{\epsilon}^\top \mathbf{z}^\top \mathbf{B}^\top \right]^\top \quad (52)$$

Por fim, $\mathbf{v}(\boldsymbol{\beta})$  o SSF para esse conjunto de parmetros. Ou ainda, o campo de vagarosidade (tambm denotado SSF, por abuso de notacoo)

$$\mathbf{s}(\boldsymbol{\beta}) = \frac{1}{\mathbf{v}(\boldsymbol{\beta})} \quad (53)$$

Funo-custo e erro quadrtico

De forma semelhante  TTT, ser usada uma minimizao iterativa, alternando entre encontrar o SSF (agora parametrizado por $\boldsymbol{\beta}$) e a matriz de distncias. Matematicamente, $\boldsymbol{\beta}_i$  o vetor de parmetros da i -sima iterao, e $\mathbf{R}_i \equiv \mathbf{R}(\mathbf{s}(\boldsymbol{\beta}_i)) \in \mathbb{R}^{M \times N}$  a matriz de distncias para o SSF definido por $\boldsymbol{\beta}$. A funo custo ser

$$E(\boldsymbol{\beta}_i) = \|\mathbf{R}_{i-1} \mathbf{s}(\boldsymbol{\beta}_i) - \mathbf{t}_{\text{obs}}\|^2 \quad (54)$$

onde assume-se $\mathbf{R}_{i-1}$ constante. Expandindo a norma ℓ_2 da Eq. (54), tem-se

$$E(\boldsymbol{\beta}_i) = \sum_{m=0}^{M-1} E_m^2(\boldsymbol{\beta}_i) \quad (55)$$

onde

$$E_m(\boldsymbol{\beta}_i) = \sum_{n=0}^{N-1} r_{m,n;i-1} s_{n;i} - t_{\text{obs};m} \quad (56)$$

em que $r_{m,n;i-1} = [\mathbf{R}_{i-1}]_{(m,n)}$ é a distância percorrida pela m -ésima onda (fonte-receptor) dentro da n -ésima célula na $i-1$ -ésima iteração; $s_{n;i}$ é a vagarosidade da n -ésima célula na (i) -ésima iteração (a atual), sendo função de $\boldsymbol{\beta}_i$ (ou mais especificamente, dos elementos de $\boldsymbol{\beta}_i$ que correspondem à coluna na qual a n -ésima célula se encontra); e $t_{\text{obs};m}$ é o tempo de trânsito da m -ésima onda.

Denota-se também $\mathbf{e}_{i-1} \in \mathbb{R}^{M \times 1}$ um vetor dos resíduos, com $[\mathbf{e}_i]_{(m)} = E_m(\boldsymbol{\beta}_i)$.

Ressaltaremos que, nas formulações anteriores, foi usada uma notação em i que definia a próxima iteração $(i+1)$ com base na atual. Por limpeza e espaço, aqui será usada uma notação que define a iteração atual i com base na anterior $i-1$.

Minimização e o algoritmo de Gauss-Newton

É notável que a relação entre a função-custo $E(\boldsymbol{\beta}_i)$ e a variável de minimização $\boldsymbol{\beta}_i$ é não-linear. Enquanto na TTT clássica, a função-custo é estritamente uma função quadrática em relação aos parâmetros de otimização (o vetor de vagarosidade $\mathbf{s}_i$), aqui o comportamento de $\mathbf{s}_i$ é regido pelos parâmetros de $\boldsymbol{\beta}_i$. Isso faz com que a solução por inversão não seja direta, e tampouco possua uma forma fechada para sua solução.

Para tratar desse problema não-linear, utilizaremos o algoritmo de Gauss-Newton (GNa). Para tal, denota-se $\boldsymbol{\beta}_{i,j}$ como a j -ésima iteração (dentro do GNa) do vetor de parâmetros, na i -ésima iteração da estimação do SSF. Também escrevemos $\mathbf{J}_{i,j} \in \mathbb{R}^{M \times 4N_x}$ como o Jacobiano de $\mathbf{e}_{i,j}$ em relação a $\boldsymbol{\beta}_{i,j}$; ou ainda,

$$[\mathbf{J}_{i,j}]_{(m,k)} = \frac{\partial E_m}{\partial \beta_{k;i,j}}(\boldsymbol{\beta}_{i,j}) \quad (57)$$

O GNa é inicializado com $\boldsymbol{\beta}_{i,\{j=0\}} = \boldsymbol{\beta}_{i-1}^*$, recebendo o vetor de parâmetros ótimo da solução anterior (em i).

Lembrando que $s_{n;i-1,j} = \frac{1}{v_{n;i-1,j}}$, é fácil mostrar que

$$\frac{\partial E_m}{\partial V_{k;i,j}} = \sum_{n=0}^{N-1} f_{m,n;i,j} (1 + \epsilon_{k;i,j} g_z(z_{k;i,j}, B_{k;i,j})) \quad (58a)$$

$$\frac{\partial E_m}{\partial \epsilon_{k;i,j}} = V_{k;i,j} \sum_{n=0}^{N-1} f_{m,n;i,j} g_z(z_{k;i,j}, B_{k;i,j}) \quad (58b)$$

$$\frac{\partial E_m}{\partial z_{k;i,j}} = V_{k;i,j} \epsilon_{k;i,j} \frac{2}{B_{k;i,j}} \sum_{n=0}^{N-1} f_{m,n;i,j} \left(e^{-\eta_z(z_{k;i,j}, B_{k;i,j})} - 1 \right) \quad (58c)$$

$$\frac{\partial E_m}{\partial B_{k;i,j}} = V_{k;i,j} \epsilon_{k;i,j} \sum_{n=0}^{N-1} f_{m,n;i,j} \frac{\eta_z(z_{k;i,j}, B_{k;i,j})}{B_{k;i,j}} \left(e^{-\eta_z(z_{k;i,j}, B_{k;i,j})} - 1 \right) \quad (58d)$$

$$f_{m,n;i,j} = -\Delta_{n,k} s_{n;i,j}^2 r_{m,n;i-1} \quad (58e)$$

$$g_z(z_{k;i,j}, B_{k;i,j}) = \left[e^{-\eta_z(z_{k;i,j}, B_{k;i,j})} + \eta_z(z_{k;i,j}, z_{k;i,j}) - 1 \right] \quad (58f)$$

$$\eta_z(z_{k;i,j}, B_{k;i,j}) = \frac{2(z_n - z_{k;i,j})}{B_{k;i,j}} \quad (58g)$$

em que $V_{k;i,j}$, $\epsilon_{k;i,j}$, $z_{k;i,j}$ e $B_{k;i,j}$ so os $[k, N_x + k, 2N_x + k, 3N_x + k]$ -simos elementos de $\beta_{i,j}$, e z_n  a profundidade da n -sima clula. $\Delta_{n,k}$  uma verso modificada do delta de Dirac, sendo 1 se a n -sima clula pertence  k -sima coluna, e 0 caso contrrio.

Tendo o Jacobiano $\mathbf{J}_{i,j}$, o vetor de resduos $\mathbf{e}_{i,j}$, e o vetor de parmetros $\beta_{i,j}$, pelo GNa tem-se ento

$$\beta_{i,j+1} = \beta_{i,j} - [\mathbf{J}_{i,j}^T \mathbf{J}_{i,j}]^{-1} \mathbf{J}_{i,j}^T \mathbf{e}_{i,j} \quad (59)$$

Esse processo iterativo  repetido em j at ocorrer a convergncia em $\beta_{i,j+1}$; momento no qual se extrai $\beta_i^* = \beta_{i,j}$.

Para que esse processo seja vlido,  necessrio e suficiente que $\text{rank}(\mathbf{J}_{i,j}) = 4N_x \leq M$. Contudo, essa condio no  garantida verdadeira.

Regularizao com referncia

O perfil de Munk  definido com um conjunto de parmetros, geralmente $V_0 = 1500\text{m/s}$, $\epsilon_0 = 0.00737$, $z_0 = 1300\text{m}$, e $B_0 = 1300\text{m}$. Esses valores podem ser usados como referncias para a minimizao apresentada anteriormente, atravs de uma regularizao aditiva.

Definimos $F(\beta_{i,j})$ como um erro quadrtico entre os parmetros a sere estimados e os valores-base de referncia, dado por

$$F(\beta_{i,j}) = \|\mathbf{A}(\beta_{i,j} - \beta_{\text{ref}})\|^2 \quad (60)$$

em que $\beta_{\text{ref}} \in \mathbb{R}^{4N_x \times 1}$  o vetor de referncia, em que cada bloco de N_x valores  igual ao respectivo valor de referncia citado anteriormente; e $\mathbf{A} \in \mathbb{R}^{4N_x \times 4N_x}$  uma matriz diagonal com parmetros de regularizao, dada por

$$\mathbf{A} = \begin{bmatrix} \alpha_v \mathbf{I} & 0 & 0 & 0 \\ 0 & \alpha_\epsilon \mathbf{I} & 0 & 0 \\ 0 & 0 & \alpha_z \mathbf{I} & 0 \\ 0 & 0 & 0 & \alpha_B \mathbf{I} \end{bmatrix} \quad (61)$$

Os elementos de $\mathbf{A}$ servem simultaneamente para controlar o quo “pesada”  a regularizao, e tambm normalizar o impacto dos parmetros, dada a diferena de ordem entre eles.

Por usarmos uma regularizao quadrtica, seu Jacobiano ser $\mathbf{F}'_{i,j} = \mathbf{A}$. Com isso, a iterao do GNa se torna

$$\beta_{i,j+1} = \beta_{i,j} - [\mathbf{J}_{i,j}^T \mathbf{J}_{i,j} + \mathbf{F}_{i,j}'^T \mathbf{F}_{i,j}']^{-1} (\mathbf{J}_{i,j}^T \mathbf{e}_{i,j} + \mathbf{F}_{i,j}'^T \mathbf{F}_{i,j}' [\beta_{i,j} - \beta_{\text{ref}}]) \quad (62)$$

Alternativamente, essa regularizao poderia ser feita sobre o SSF reconstrudo usando as Eqs. (51) a (53), ao invs do vetor de parmetros; ou uma regularizao que relacionasse os parmetros entre colunas adjacentes. A regularizao utilizada foi escolhida por simplicidade matemtica, embora as duas outras avenidas permaneam em aberto como vias de explorao futura.

5.2 Mtodo por EOFs

Esse mtodo ser semelhante ao proposto por [26], com as devidas modificaes e adaptaes para o caso multi-dimensional, alm de algumas outras alteraes.

A modelagem por funes empricas ortogonais (EOFs, do ingls *Empirical Orthogonal Functions*) so uma abordagem possvel para reconstruo do SSF. Nela, cada coluna do SSF no  estimada diretamente, mas como uma combinao linear dentre possveis perfis previamente estimados, a partir de um banco de dados.

Construo da base de EOFs

A partir de um banco de dados com K medies de temperatura, presso, e salinidade (TPS) ao longo da coluna d’gua em uma localidade ou regio,  possvel determinar o SSP (unidimensional) nessa localidade atravs de formulaes j estabelecidas [27–29].

Denota-se $\mathbf{s}_k \in \mathbb{R}^{N_z \times 1}$ o SSP para o k -ésimo registro, e $\bar{\mathbf{s}}$ o perfil médio entre os K registros,

$$\bar{\mathbf{s}} = \frac{1}{K} \sum_{k=0}^{K-1} \mathbf{s}_k \quad (63)$$

a partir do qual define-se a matriz de covariância entre os K registros $\Phi_{\mathbf{s}} \in \mathbb{R}^{N_z \times N_z}$,

$$\Phi_{\mathbf{s}} = \frac{1}{K} \sum_{k=0}^{K-1} (\mathbf{s}_k - \bar{\mathbf{s}}) (\mathbf{s}_k - \bar{\mathbf{s}})^T \quad (64)$$

Assumindo que $\Phi_{\mathbf{s}}$ seja uma matriz de posto cheio², com $\text{rank}(\Phi_{\mathbf{s}}) = N_z$, então $\text{kern}(\Phi_{\mathbf{s}}) = \mathbb{R}^{N_z \times 1}$. Isso significa que qualquer vetor $\tilde{\mathbf{s}}$ (inclusive SSP fisicamente impossíveis) pode ser obtido como uma combinação linear das colunas de $\Phi_{\mathbf{s}}$. Por simplicidade, escreve-se que

$$\tilde{\mathbf{s}} = \bar{\mathbf{s}} + \Phi_{\mathbf{s}} \boldsymbol{\alpha} \quad (65)$$

onde $\boldsymbol{\alpha}$ é um vetor de coeficientes. Essa explicitação da vagarosidade média $\bar{\mathbf{s}}$ é feita por $\Phi_{\mathbf{s}}$ considerar somente a variação dos vetores $\mathbf{s}_k$ em relação à média, e (em geral) vai fazer com que os coeficientes de $\boldsymbol{\alpha}$ sejam mais bem comportados.

É possível decompor $\Phi_{\mathbf{s}}$ em função de seus autovalores e autovetores, levando a

$$\begin{aligned} \Phi_{\mathbf{s}} &= \sum_{n=0}^{N_z-1} \lambda_n \mathbf{v}_n \mathbf{v}_n^T \\ &= \mathbf{V} \boldsymbol{\Lambda} \mathbf{V}^{-1} \end{aligned} \quad (66)$$

com $|\lambda_1| \geq |\lambda_2| \geq \dots \geq |\lambda_{N_z-1}|$ os autovalores de $\Phi_{\mathbf{s}}$, em ordem decrescente; e $\mathbf{v}_n$ a n -ésima coluna de $\mathbf{V}$, também o autovetor de $\Phi_{\mathbf{s}}$ referente ao autovalor λ_n . Assume-se que $\Phi_{\mathbf{s}}$ seja uma matriz diagonalizável, tal que a auto-decomposição seja possível.

É possível reescrever a Eq. (65) utilizando a auto-decomposição de $\Phi_{\mathbf{s}}$, levando a

$$\tilde{\mathbf{s}} = \bar{\mathbf{s}} + \mathbf{V} \mathbf{a} \quad (67)$$

em que $\mathbf{a}$ é um (novo) vetor de coeficientes. Por fim, toma-se que apenas G dentre os N_z autovetores são suficientes para reconstruir os SSP com acurácia. Ou seja,

$$\tilde{\mathbf{s}} = \bar{\mathbf{s}} + \mathbf{V}_G \mathbf{a}_G \quad (68)$$

em que $\mathbf{V}_G \in \mathbb{R}^{N_z \times 1}$ é composto pelas G primeiras colunas de $\mathbf{V}$ — essas, referentes aos G maiores autovalores (em módulo).

Estimação do SSP

Nota: no artigo que inspirou essa formulação, foi utilizado um algoritmo genético para estimação das velocidades; aqui será usada a formulação por minimização do gradiente para estimação das vagarosidades.

Seguiremos uma estrutura semelhante à da TTT, com minimização do erro de tempo de trânsito entre o modelo e o medido. Ou seja, o problema-base é

$$E(\mathbf{a}_{i+1}) = \|\mathbf{R}_i \mathbf{s}(\mathbf{a}_{i+1}) - \mathbf{t}_{\text{obs}}\|^2 \quad (69)$$

com $\mathbf{R}_i$ sendo a i -ésima solução da equação Eikonal; aqui toma-se que $\mathbf{a}_{G;i} \equiv \mathbf{a}_i$, por simplicidade da notação. Sabendo que $\mathbf{s}(\mathbf{a}_i) = \bar{\mathbf{s}} + \mathbf{V}_G \mathbf{a}_i$, então a solução para esse problema será

$$\mathbf{a}_{i+1} = \left[\mathbf{V}_G^T \mathbf{R}_i^T \mathbf{R}_i \mathbf{V}_G \right]^{-1} \mathbf{V}_G^T \mathbf{R}_i^T (\mathbf{t}_{\text{obs}} - \mathbf{R}_i \bar{\mathbf{s}}) \quad (70)$$

²Isso pressupõe que $K > N_z$, indicando mais medições que colunas, o que pode ser inviável ou indesejado na prática.

Estimação do SSF

A formulação acima presume que a estimação é uni-dimensional. Portanto, é necessário expandi-la para o caso multi-dimensional, com algumas adaptações.

Assumamos N_x colunas, cada uma com um SSP $\mathbf{s}_{i,n} \in \mathbb{R}^{N_z \times 1}$ ($0 \leq n < N_x$). Disso, o SSF em forma matricial $\mathbf{S}_i \in \mathbb{R}^{N_z \times N_x}$ é dado por

$$\mathbf{S}_i = [\mathbf{s}_{i,0} \mid \mathbf{s}_{i,1} \mid \cdots \mid \mathbf{s}_{i,N_x-1}] \quad (71)$$

com $\mathbf{s}_i = \text{rvec}(\mathbf{S}_i)$ sendo a vetorização por linhas de $\mathbf{S}_i$. Como cada SSP $\mathbf{s}_{i,n}$ pode ser dado pela Eq. (68), então

$$\mathbf{S}_i = \bar{\mathbf{S}} + \mathbf{V}_G \mathbf{A}_i \quad (72)$$

com $\bar{\mathbf{S}}$ sendo a concatenação horizontal de N_x cópias de $\bar{\mathbf{s}}$, e $\mathbf{A}_i$ a concatenação horizontal de todos os $\mathbf{a}_{i,n}$ ($0 \leq n < N_x$), representando os coeficientes a serem estimados. Pelas propriedades da vetorização por linhas, temos que

$$\begin{aligned} \mathbf{s}_i &= \text{rvec}(\mathbf{S}_i) \\ &= \text{rvec}(\bar{\mathbf{S}}) + \text{rvec}(\mathbf{V}_G \mathbf{A}_i) \\ &= \text{rvec}(\bar{\mathbf{S}}) + (\mathbf{V}_G \otimes \mathbf{I}_{N_x}) \text{rvec}(\mathbf{A}_i) \end{aligned} \quad (73)$$

com $\otimes$ simbolizando o produto de Kronecker.

Denotando $\tilde{\mathbf{V}}_G = (\mathbf{V}_G \otimes \mathbf{I}_{N_x})$, $\tilde{\mathbf{a}}_i = \text{rvec}(\mathbf{A}_i)$, e $\tilde{\mathbf{s}}_v = \text{rvec}(\bar{\mathbf{S}})$, o problema torna-se

$$\mathbf{s}_i = \tilde{\mathbf{s}}_v + \tilde{\mathbf{V}}_G \tilde{\mathbf{a}}_i \quad (74)$$

Aliando esse resultado à estrutura de minimização quadrática,

$$E(\tilde{\mathbf{a}}_{i+1}) = \left\| \mathbf{R}_i \tilde{\mathbf{V}}_G \tilde{\mathbf{a}}_{i+1} + \mathbf{R}_i \tilde{\mathbf{s}}_v - \mathbf{t}_{\text{obs}} \right\|^2 \quad (75)$$

cujas solução é

$$\tilde{\mathbf{a}}_{i+1} = \left[\tilde{\mathbf{V}}_G^T \mathbf{R}_i^T \mathbf{R}_i \tilde{\mathbf{V}}_G \right]^{-1} \tilde{\mathbf{V}}_G^T \mathbf{R}_i^T (\mathbf{t}_{\text{obs}} - \mathbf{R}_i \tilde{\mathbf{s}}_v) \quad (76)$$

Notavelmente, o perfil $\mathbf{s}_{i+1}$ pode ser obtido pela Eq. (73).

Regularização

Duas formas de regularização podem ser consideradas aqui: sobre $\mathbf{a}_{i+1}$ (o vetor de coeficientes da EOF), ou sobre $\mathbf{s}_{i+1}$ (o vetor de vagariedades reconstruído). Por essas duas variáveis serem linearmente independentes, regularizar uma afeta diretamente a outra; contudo, a diferente notação permite uma melhor visualização da penalização adicionada.

a) Na primeira regularização, usa-se que a presença do perfil-médio $\bar{\mathbf{s}}$ no modelo implica que os coeficientes de $\mathbf{a}_{i+1}$ serão pequenos. Portanto, a adição de um termo de regularização $\alpha^2 \|\tilde{\mathbf{a}}_{i+1}\|^2$ à Eq. (75) modifica a solução para

$$\tilde{\mathbf{a}}_{i+1} = \left[\tilde{\mathbf{V}}_G^T \mathbf{R}_i^T \mathbf{R}_i \tilde{\mathbf{V}}_G + \alpha^2 \mathbf{I}_{GN_x} \right]^{-1} \tilde{\mathbf{V}}_G^T \mathbf{R}_i^T (\mathbf{t}_{\text{obs}} - \mathbf{R}_i \tilde{\mathbf{s}}_v) \quad (77)$$

b) Na segunda regularização, deseja-se melhorar a suavidade do perfil. Disso, o termo de regularização adicionado será $\alpha^2 \|\mathbf{D}\mathbf{s}_{i+1}\|^2$, que leva à solução

$$\tilde{\mathbf{a}}_{i+1} = \left[\tilde{\mathbf{V}}_G^T \left(\mathbf{R}_i^T \mathbf{R}_i + \alpha^2 \mathbf{D}^T \mathbf{D} \right) \tilde{\mathbf{V}}_G \right]^{-1} \tilde{\mathbf{V}}_G^T \left(\mathbf{R}_i^T [\mathbf{t}_{\text{obs}} - \mathbf{R}_i \tilde{\mathbf{s}}_v] - \alpha^2 \mathbf{D}^T \mathbf{D} \tilde{\mathbf{s}}_v \right) \quad (78)$$

Em ambos os casos, dado que a regularização não afeta o SSF objetivo, o perfil $\mathbf{s}_{i+1}$ é reconstruído também utilizando a Eq. (73).

Ambas regularizações possuem formato semelhante, mas buscam impactar a solução de maneira diferente: a regularização (a) penaliza a variância dos coeficientes dos EOFs; enquanto a regularização (b) penaliza a variância (entre células) do SSF reconstruído.

6 Resultados utilizando métodos adaptados de TTT e alternativos

Nessa seção, serão discutidos as simulações e resultados para as técnicas apresentadas na Seções 4 e 5. O ambiente será o mesmo que utilizado na Seção 3, e apresentados nas Figs. 1 e 2. Também serão comparados os resultados para as duas condições de distribuição de dispositivos utilizados na Seção 3, com eles no entorno ou em camadas. As métricas, e o processo de estimação, também serão idênticos aos anteriormente apresentados.

Todas as equações e formulações utilizadas foram normalizadas em um processo semelhante ao da Seção 4.4, com as devidas modificações sendo realizadas. Isso foi omitido por questão de espaço e organização.

6.1 Base de EOF e perfil de referência

Algumas das técnicas a serem comparadas dependem de uma base ortogonal de vetores, ou de um perfil de referência para a regularização.

Os parâmetros necessários para a EOF (perfil médio ou de referência, e base de autovetores para a EOF) foram obtidos também através do banco de dados da WOA com a biblioteca GSW, a partir dos perfis mensais disponíveis no banco de dados para a região escolhida. Dos 108 perfis obtidos, a base de EOF é constituída de apenas 6, tal que a variabilidade utilizando esses 6 perfis é $\geq 99.95\%$.

6.2 Técnicas

As seguintes técnicas serão comparadas:

Média

Nessa “técnica”, assume-se que a velocidade em cada ponto é a velocidade do perfil de referência na respectiva profundidade. Ela servirá como um *baseline* para comparação das outras.

Split

A técnica separada em camadas (denominada “*split*”) baseia-se na Eq. (46). Em ambas as distribuições de dispositivos usou-se $\alpha = 4.92$, e a profundidade de *cut-off* é $z_0 = 1000\text{m}$; ou seja, abaixo dessa profundidade o perfil é assumido igual ao de referência (tomado como a média dos perfis mensais também obtidos pelo WOA + GSW), e a estimação é realizada acima disso.

Trade-off

A técnica de *trade-off* (homônima) será baseada na mostrada na Eq. (47). Serão usados $\alpha = 2.06$ com $\beta = 0.2$ para a distribuição no entorno, e $\alpha = 2.06$ com $\beta = 0.31$ para a distribuição em camadas. Em ambos, usa-se $z_0 = 0\text{m}$, fazendo com que o perfil ao longo de toda a profundidade seja regularizado pelo termo de erro sobre a referência (mesma que anteriormente), além da regularização por suavidade.

Parametrização por Munk

A técnica baseada na parametrização pelo perfil de Munk (denominada “parametrizada” ou “param.” por espaço) utilizará os desenvolvimentos da Seção 5.1. Para ela, serão utilizados os parâmetros $[\alpha_v, \alpha_e, \alpha_z, \alpha_B] = [0.001, 2.06, 0.01, 0.0001]$ para a distribuição no entorno, e $[\alpha_v, \alpha_e, \alpha_z, \alpha_B] = [0.003, 1.33, 0.01, 0.0001]$ para a em camadas.

EOF-p

Será usada a estimação por EOFs com regularização por coeficientes pequenos (chamada “EOF-p”), mostrada na Seção 5.2, com coeficientes pela Eq. (77). Com ela, será tomado $\alpha = 0.76$ para a distribuição no entorno, e $\alpha = 0.31$ para a em camadas.

EOF-s

A última técnica é a estimação por EOFs com regularização por suavidade (chamada “EOF-s”), também mostrada na Seção 5.2, com coeficientes pela Eq. (78). Serão usados $\alpha = 3.09$ para os dispositivos no entorno, e $\alpha = 7.01$ para os dispositivos em camadas.

6.3 Resultados e discussão

As Figs. 5 e 6 mostram os erros RMS de tempo de trânsito (Fig. 5) e de velocidade (Fig. 6), com uma sub-figura para cada um dos cenários de distribuição dos dispositivos.

As Figs. 7 e 8 mostram os erros dos SSPs em relação ao perfil de velocidade c_{true} , para os casos em camadas (Fig. 7) e no entorno (Fig. 8), com uma sub-figura para cada um dos métodos utilizados para a estimação do SSF. Para essas figuras, ressaltamos que os eixos x de cada uma podem ter limites consideravelmente diferentes, e isso deve ser levado em consideração na análise.

Análise por distribuição de dispositivos

a) Na distribuição em camadas, nota-se que todas as técnicas alcançaram resultados muito semelhantes de erro residual de tempo de trânsito (Fig. 5a). Contudo, os resultados de erro RMS do SSF (Fig. 6a) mostram que os seus desempenhos em estimar o SSF foram extremamente variados. As melhores técnicas nitidamente foram a EOF-p, seguida da *trade-off* e da EOF-s, com a única que superou o uso do perfil médio tendo sido a EOF-p.

Utilizando a Fig. 7 (mais especificamente, as Figs. 7c, 7e e 7f), nota-se que o erro para as EOF-p e a *trade-off* seguem uma distribuição ao longo da profundidade muito semelhante a usar a média (Fig. 7a). Isso indica que, nesses dois métodos, o perfil de cada coluna se aproxima muito do perfil médio/de referência, não capturando as nuances da variação da velocidade do som para cada coluna d’água.

b) Já na distribuição de dispositivos no entorno, vemos que todas as técnicas (exceto a parametrizada) alcançaram desempenhos semelhantes de RMSE_t , conforme a Fig. 5b, com a parametrizada por Munk obtendo erros consideravelmente maiores. Os resultados de erro de SSF, da Fig. 6b, também mostram que as técnicas atingiram resultados melhores (exceto a parametrizada), com as três citadas anteriormente (*trade-off*, EOF-p, e EOF-s) + a técnica *split* ainda apresentando performances melhores, e agora ainda mais próximas. Além disso, todas (exceto parametrizada) alcançaram um desempenho quase idêntico ao uso direto do perfil médio sem otimização, em relação à estimação do SSF.

Utilizando agora as Figs. 8c, 8e e 8f da Fig. 8, temos que a EOF-p ainda se assemelha consideravelmente à por perfil médio, com as outras três (*split*, *trade-off*, e EOF-s) se diferenciando minimamente.

Análise por técnica

Como já debatido, os melhores resultados foram alcançados com as técnicas *trade-off*, EOF-p, e EOF-s. Os seus resultados não serão re-discutidos, pois já foram analisados.

a) Considerando todos os resultados das figuras apresentadas, é nítido que a utilização da parametrização por Munk não foi capaz de estimar o perfil na prática, nem mesmo de maneira básica. Embora interessante de forma teórica, isso indica que ela é frágil e depende que o SSF original tenha um comportamento próximo ao de Munk.

b) Há também a técnica *split* (onde estima-se o SSF somente acima de 1000m). Embora ela tenha um desempenho inferior às outras selecionadas no cenário em camadas, seu desempenho é idêntico a elas para o caso no entorno (comparando a Fig. 8b com as Figs. 8c, 8e e 8f).




Figura 5: Evolução dos erros RMS de tempo de trânsito da estimação do SSF, para os métodos mostrados, nos cenários de dispositivos (a) em camadas e (b) no entorno, ao longo de 10 iterações.




Figura 6: Evolução dos erros RMS de estimação do SSF, para os métodos mostrados, nos cenários de dispositivos (a) em camadas e (b) no entorno, ao longo de 10 iterações.




Figura 7: Erros de estimação de cada SSP, para os métodos mostrados, no cenário de dispositivos em camadas, para a iteração final.




Figura 8: Erros de estimação de cada SSP, para os métodos mostrados, no cenário de dispositivos no entorno, para a iteração final.

Discussão

É interessante ressaltar que as 4 técnicas que tiveram desempenhos minimamente satisfatórios para o caso de dispositivos em camadas (*split*, *trade-off*, EOF-p, e EOF-s) necessitam de informações prévias sobre o ambiente para a sua operação. Isso leva a uma dependência dessas técnicas em informações previamente disponibilizadas (direta ou indiretamente) de velocidade do som. Além disso, os perfis reconstruídos com essas 4 técnicas, apesar de utilizarem informações *a priori*, ainda apresentam erros médios na faixa de

0.8 ~ 1.5m/s. Considerando que a mdia dos desvios-padres de cada profundidade  0.8964m/s, o resultado  semelhante (ou levemente pior) a simplesmente utilizar o perfil mdio, sem necessitar de uma inverso. Isso  reforando comparando as suas respectivas figuras nas Figs. 7 e 8 com a utilizando a mdia, tambm nessas figuras.

7 Mtricas de qualidade

Tomemos o processo da TTT tradicional iterativa com regularizaco. Enquanto $\mathbf{D}$  fixado *a priori* e  escolhido com base na mtrica secundria e $\mathbf{t}_{\text{obs}}$ depende diretamente das medies realizadas, ambas interferindo diretamente no problema de minimizaco; o problema de inverso  primariamente afetado pelo operador direto $\mathbf{R}_i$. Alm disso, esse operador  diretamente afetado pelas condies de contorno do problema, em especfico a distribuo de dispositivos (fontes e receptores) no ambiente, a resoluo da discretizaco do ambiente, e outras variveis relacionadas aos dispositivos (como possivelmente direcionalidade, rudo, etc.).

Portanto, ser capaz de relacionar a qualidade da inverso (ou seja, quo prximo o $\mathbf{s}_{i+1}$ estimado  do $\mathbf{s}_{\text{true}}$) com as informaes *a priori* (em particular, com $\mathbf{R}_i$)  importante.

7.1 Mtricas de soluo tima sem regularizaco

Para desacoplar o problema de inverso do resultado esperado, as mtricas so auferidas considerando $\mathbf{R}$, a soluo da equaco Eikonal obtida atravs do vetor de vagarosidades real $\mathbf{s}_{\text{true}}$; ou seja, assumindo que partiu-se da soluo exata, qual o desempenho do processo de inverso. Isso dar um limite superior para a performance da etapa de inverso.

Nmero de condicionamento

A notaco utilizada aqui ser derivada e equivalente  apresentada na Seo 2.

Dada a matriz $\mathbf{R}$, com M valores singulares σ_m , o nmero de condicionamento ser κ , dado por

$$\kappa = \|\mathbf{R}\|_2 \|\mathbf{R}^{-1}\|_2 \quad (79)$$

em que $\|\mathbf{R}\|_2$  a norma Euclidiana; que, nesse caso, $\|\mathbf{R}\|_2 = \sigma_1$, o maior valor singular de $\mathbf{R}$. Dada a suposio que $\mathbf{R} \in \mathbb{R}^{M \times N}$, com $M < N$, ento $\mathbf{R}$ no  inversvel, e portanto $\kappa \rightarrow \infty$. Alternativamente, define-se κ_p utilizando a pseudo-inversa,

$$\begin{aligned} \kappa_p &= \|\mathbf{R}\|_2 \|\mathbf{R}^\dagger\|_2 \\ &= \frac{\sigma_1}{\sigma_R} \end{aligned} \quad (80)$$

com σ_R sendo o menor valor singular no-nulo de $\mathbf{R}$.

Ambas essas mtricas (κ e κ_p) aferem primariamente a sensibilidade da inverso a perturbaes em $\mathbf{t}$, e a estabilidade da inverso.

Para obter uma mtrica em um domnio limitado, define-se K

$$\begin{aligned} K &= \frac{1}{\kappa_p} \\ &= \frac{\sigma_R}{\sigma_1} \end{aligned} \quad (81)$$

em que $K \approx 1$ indica que a inverso  estvel e pouco sensvel a perturbaes no tempo de trnsito, e $K \approx 0$ indica uma soluo instvel. Essa mtrica ser chamada de "recproco de condicionamento".

Ranque

O ranque de uma matriz rank ($\mathbf{R}$)  a dimenso do espao gerado pelas suas colunas, e pode ser definido como a quantidade de valores singulares no-nulos. No nosso contexto, rank ($\mathbf{R}$) = R est associado ao nmero

de condicionamento, e ao espectro da SVD. Contudo, ele é sensível a valores singulares muito pequenos, que podem surgir em problemas mal-postos.

Disso, é comum usar o ranque estável r [30], dado por

$$r = \frac{\sigma^T \sigma}{\sigma_1^2} = \frac{\sum_{m=0}^{M-1} \sigma_m^2}{\sigma_1^2} \quad (82)$$

como uma métrica mais robusta para medir a dimensão do espaço alcançável através do operador direto $\mathbf{R}$.

Outra métrica disponível baseada no ranque é o ranque entrópico r_e [31], cuja derivação assemelha-se à definição de entropia da teoria da informação [32]. Uma de suas formulações é

$$r_e = \exp \left\{ - \sum_{m=0}^{M-1} p_m \ln p_m \right\} = \prod_{m=0}^{M-1} p_m^{-p_m} \quad (83)$$

com $p_m = \sigma_m \left[\sum_{m'=0}^{M-1} |\sigma_{m'}| \right]^{-1}$. A interpretação desse coeficiente é como a “dimensão média” dentre todas as soluções alcançáveis usando $\mathbf{R}$.

Resolução

Como já debatido, a solução para o problema (sem regularização) pode ser dada por $\mathbf{s} = \mathbf{R}^\dagger \mathbf{t}_{\text{obs}}$. Dado que tomou-se $\mathbf{R}$ como sendo a solução do problema Eikonal utilizando o vetor de vagarosidades $\mathbf{s}_{\text{true}}$, então $\mathbf{t}_{\text{obs}} = \mathbf{R} \mathbf{s}_{\text{true}}$, e portanto $\mathbf{s} = \mathbf{R}^\dagger \mathbf{R} \mathbf{s}_{\text{true}}$. Para que mantenha-se a relação $\mathbf{s} = \mathbf{s}_{\text{true}}$ (ou seja, a vagarosidade real é um ponto estacionário do problema iterativo de estimação), é necessário que $\mathbf{R}^\dagger \mathbf{R} = \mathbf{I}$.

Além disso, a estrutura de $\mathbf{R}^\dagger \mathbf{R}$ (caso essa não seja a identidade) também revela informações quanto ao problema de inversão, especificamente o elemento (i, j) de $\mathbf{R}^\dagger \mathbf{R}$ indica a correlação entre os i - e j -ésimos elementos de $\mathbf{s}$.

A “diagonalidade” da matriz pode ser mensurada com diferentes métricas, a mais simples delas sendo

$$\mathcal{D} = \frac{\left\| \text{diag} \left(\mathbf{R}^\dagger \mathbf{R} \right) \right\|^2}{\left\| \mathbf{R}^\dagger \mathbf{R} \right\|_F^2} \quad (84)$$

em que $\text{diag} \left(\mathbf{R}^\dagger \mathbf{R} \right)$ extrai o vetor que está na diagonal principal de $\mathbf{R}^\dagger \mathbf{R}$. Naturalmente, $\mathcal{D} = 1$ indica que $\mathbf{R}^\dagger \mathbf{R} = \mathbf{I}$, e $\mathcal{D}$ pequeno indica um forte acoplamento entre os diferentes coeficientes, após a inversão.

Coerência

Dada $\boldsymbol{\rho}_n$ a n -ésima coluna de $\mathbf{R}$ ($0 \leq n < N$), a coerência entre $\boldsymbol{\rho}_i$ e $\boldsymbol{\rho}_j$ é dada por

$$\alpha_{i,j} = \frac{\boldsymbol{\rho}_i^\top \boldsymbol{\rho}_j}{\sqrt{\boldsymbol{\rho}_i^\top \boldsymbol{\rho}_i \boldsymbol{\rho}_j^\top \boldsymbol{\rho}_j}} \quad (85)$$

essa sendo uma métrica da proximidade do efeito que duas células diferentes tem na construção de $\mathbf{t} = \mathbf{R} \mathbf{s}$. A coerência de $\mathbf{R}$ é

$$\alpha = \frac{2}{N(N-1)} \sum_{\substack{0 \leq i,j < N \\ i \leq j}} \alpha_{i,j} \quad (86)$$

indicando a coerência máxima entre duas colunas diferentes de $\mathbf{R}$. Um α pequeno indica que a coerência máxima é pequena, e portanto as células são distinguíveis na reconstrução do tempo de trânsito. Por outro lado, um $\alpha \approx 1$ indica que há células que são indistinguíveis.

Assim como foi definida a coerência entre as colunas, é possível definir a coerência entre as linhas de $\mathbf{R}$. Denota-se $\mathbf{r}_n$ a n -ésima linha de $\mathbf{R}$ ($0 \leq n < M$), e

$$a_{i,j} = \frac{\mathbf{r}_i^T \mathbf{r}_j}{\sqrt{\mathbf{r}_i^T \mathbf{r}_i \mathbf{r}_j^T \mathbf{r}_j}} \quad (87)$$

é a coerência entre as linhas i e j . Enquanto a coerência entre colunas mede a identificabilidade de cada um dos parâmetros, a coerência entre linhas mede a colinearidade entre medições. Um $a_{i,j}$ pequeno indica que os trajetos das medições i e j são distintos, com poucas células em comum; enquanto um $a_{i,j} \approx 1$ indica que os trajetos são muito semelhantes.

Agora, ao invés de definirmos a coerência como a máxima entre linhas, define-se (com uma formulação semelhante à da entropia)

$$A = -\frac{2}{e M(M-1)} \sum_{\substack{0 \leq i,j < M \\ i \leq j}} a_{i,j} \ln(a_{i,j}) \quad (88)$$

Essa métrica mede o quão redundantes/interdependentes são as medições que produzem a matriz $\mathbf{R}$. A intuição em utilizar a notação de entropia é de que trajetos idênticos não trazem informação útil já que eles são iguais; mas trajetos estritamente diferentes (sem um mínimo de *crosstalk*) também não são úteis, já que isso causa desatrelamento entre conjuntos de células, tornando o problema separável e induzindo *overfitting*. Nesses dois casos ($a_{i,j} \rightarrow 0$ e $a_{i,j} \rightarrow 1$), temos que $a_{i,j} \ln(a_{i,j}) \rightarrow 0$.

Resumo

Reapresentaremos as métricas mostradas, de uma maneira mais sucinta.


Recíproco de condicionamento K	$(0, 1]$	Estabilidade e sensibilidade a perturbações
Ranque R	$[1, M]$	Dimensão do espaço estimável
Ranque estável r	$[1, M]$	Dimensão robusta do espaço
Ranque entrópico r_e	$[1, M]$	Dimensão média do espaço
Resolução $\mathcal{D}$	$[0, 1]$	Independência entre células
Coerência-coluna α	$[0, 1]$	Individualidade entre células
Coerência-linha A	$[0, 1]$	Redundância e dependência entre medições

7.2 Análise qualitativa das métricas

Dadas as métricas apresentadas, elas serão qualitativamente avaliadas de forma a verificar se os valores obtidos para diferentes condições se alinham com o esperado dada a interpretação de cada métrica.

Considerando que essas métricas são primariamente afetadas pelo ambiente, serão consideradas 5 distribuições diferentes de dispositivos:

- Em camadas,
- e no entorno, ambas já apresentadas e utilizadas anteriormente nas simulações;
- Fontes no fundo em uma camada única, e receptores como várias camadas próximas à superfície, simulando várias passagens em profundidades diferentes;
- Fontes no fundo em uma camada única, e receptores em uma camada na superfície + uma coluna única até determinada profundidade, simulando uma passagem horizontal e uma vertical;
- Fontes no fundo em uma camada única, e receptores em uma camada na superfície + um trajeto “diagonal” até determinada profundidade, simulando uma passagem horizontal e uma diagonal.



Referncias

- [1] V. G. P. Curtarelli, *Reviso bibliogrfica do estado da arte de Travel-Time Tomography, inverso utilizando tempo de trnsito, e inverso do campo de velocidade do som na coluna d'gua*, 2026.
- [2] K. Alton e I. M. Mitchell, "Fast Marching Methods for Stationary Hamilton–Jacobi Equations with Axis-Aligned Anisotropy," *SIAM Journal on Numerical Analysis*, v. 47, n. 1, pp. 363–385, jan. de 2009.
- [3] W.-K. Jeong e R. T. Whitaker, "A Fast Iterative Method for Eikonal Equations," *SIAM Journal on Scientific Computing*, v. 30, n. 5, pp. 2512–2534, jan. de 2008.
- [4] R. Ali, S. Hsieh e J. Dahl, "Open-source Gauss-Newton-based methods for refraction-corrected ultrasound computed tomography," em *Medical Imaging 2019: Ultrasonic Imaging and Tomography*, N. V. Ruiter e B. C. Byram, ed., San Diego, United States: SPIE, 15 de mar. de 2019, p. 7.
- [5] A. Hormati, I. Jovanović, O. Roy e M. Vetterli, "Robust ultrasound travel-time tomography using the bent ray model," apresentado em SPIE Medical Imaging, J. D'hooge e S. A. McAleavey, ed., San Diego, California, USA, 4 de mar. de 2010, p. 76290I.
- [6] M. Zhang e Y. Xu, "Inversion of the Sound Speed With Radiated Noise of an Autonomous Underwater Vehicle in Shallow Water Waveguides," *IEEE Journal of Oceanic Engineering*, v. 41, n. 1, pp. 204–216, jan. de 2016.
- [7] H.-g. Tang, R.-j. Xie, Y. Wu, C.-s. Zhou, J.-l. Yuan e W. Qin, "Travel time tomography by ray tracing using the fast sweeping method," *Applied Geophysics*, v. 21, n. 4, pp. 697–714, dez. de 2024.
- [8] J. C. A. Barata e M. S. Hussein, "The Moore–Penrose Pseudoinverse: A Tutorial Review of the Theory," *Brazilian Journal of Physics*, v. 42, n. 1–2, pp. 146–165, abr. de 2012.
- [9] G. Golub e W. Kahan, "Calculating the Singular Values and Pseudo-Inverse of a Matrix," *Journal of the Society for Industrial and Applied Mathematics Series B Numerical Analysis*, v. 2, n. 2, pp. 205–224, jan. de 1965.
- [10] M. Brand, "Fast low-rank modifications of the thin singular value decomposition," *Linear Algebra and its Applications*, v. 415, n. 1, pp. 20–30, mai. de 2006.
- [11] J. T. Chen, I. L. Chen e K. H. Chen, "Treatment of rank deficiency in acoustics using SVD," *Journal of Computational Acoustics*, v. 14, n. 02, pp. 157–183, jun. de 2006.
- [12] J. Zhang, U. S. Ten Brink e M. N. Toksz, "Nonlinear refraction and reflection travel time tomography," *Journal of Geophysical Research: Solid Earth*, v. 103, n. B12, pp. 29 743–29 757, 10 de dez. de 1998.
- [13] F. Delprat-Jannaud e P. Lailly, "Ill-posed and well-posed formulations of the reflection travel time tomography problem," *Journal of Geophysical Research: Solid Earth*, v. 98, n. B4, pp. 6589–6605, 10 de abr. de 1993.
- [14] W. S. Phillips e M. C. Fehler, "Traveltime tomography: A comparison of popular methods," *GEOPHYSICS*, v. 56, n. 10, pp. 1639–1649, out. de 1991.
- [15] K. A. Meyerholtz, G. L. Pavlis e S. A. Szpakowski, "Convolutional quelling in seismic tomography," *GEOPHYSICS*, v. 54, n. 5, pp. 570–580, mai. de 1989.
- [16] D. P. Berrar, W. Dubitzky e M. Granzow, ed., *A Practical Approach to Microarray Data Analysis*, 1st ed. 2003. New York, NY: Springer US, 2003, 1 p.
- [17] H. E. Garcia et al., "World Ocean Atlas 2023, Volume 3: Dissolved Oxygen, Apparent Oxygen Utilization, and Dissolved Oxygen Saturation," *NOAA Atlas NESDIS ; 91*, 2024.
- [18] T. J. McDougall e P. M. Barker, *Getting Started with TEOS-10 and the Gibbs Seawater (GSW) Oceanographic Toolbox*. Battery Point, Tas.: Trevor J McDougall, 2011.
- [19] K. Ganster, *Solving the (factored) eikonal equation with the Fast Marching method*, verso 0.9.8, 2025.
- [20] J. A. Sethian, "Fast Marching Methods," *SIAM Review*, v. 41, n. 2, pp. 199–235, jan. de 1999.
- [21] D. L. Chopp, "Some Improvements of the Fast Marching Method," *SIAM Journal on Scientific Computing*, v. 23, n. 1, pp. 230–244, jan. de 2001.
- [22] W. Munk, P. Worcester e C. Wunsch, *Ocean Acoustic Tomography* (Cambridge Monographs on Mechanics), 1.publ. Cambridge: Cambridge University Press, 1995, 433 pp.
- [23] L. Possenti et al., "The present and future contribution of ships to the underwater soundscape," *Frontiers in Marine Science*, v. 11, p. 1252901, 8 de mar. de 2024.
- [24] W. H. Munk, "Sound channel in an exponentially stratified ocean, with application to SOFAR," *The Journal of the Acoustical Society of America*, v. 55, n. 2, pp. 220–226, 1 de fev. de 1974.

- [25] P. Wu, J. Sun, G. Shan, Z. Sun e P. Wei, “Inversion of Deep-Water Velocity Using the Munk Formula and the Seabed Reflection Traveltime: An Inversion Scheme That Takes the Complex Seabed Topography Into Account,” *IEEE Transactions on Geoscience and Remote Sensing*, v. 61, pp. 1–14, 2023.
- [26] S. Radhakrishnan e A. K., “Inversion for water column sound speed profile from acoustic travel times using empirical orthogonal functions,” *The Journal of the Acoustical Society of America*, v. 156, n. 6, pp. 4061–4072, 1 de dez. de 2024.
- [27] V. A. Del Grosso, “New equation for the speed of sound in natural waters (with comparisons to other equations),” *The Journal of the Acoustical Society of America*, v. 56, n. 4, pp. 1084–1091, 1 de out. de 1974.
- [28] K. V. Mackenzie, “Nine-term equation for sound speed in the oceans,” *The Journal of the Acoustical Society of America*, v. 70, n. 3, pp. 807–812, 1 de set. de 1981.
- [29] W. D. Wilson, “Equation for the Speed of Sound in Sea Water,” *The Journal of the Acoustical Society of America*, v. 32, n. 10, pp. 1357–1357, 1 de out. de 1960.
- [30] I. C. F. Ipsen e A. K. Saibaba, “Stable Rank and Intrinsic Dimension of Real and Complex Matrices,” *SIAM Journal on Matrix Analysis and Applications*, v. 46, n. 3, pp. 1988–2007, 30 de set. de 2025.
- [31] O. Roy e M. Vetterli, “The Effective Rank: A Measure of Effective Dimensionality,” 2007.
- [32] R. M. Gray, *Entropy and Information Theory*. Boston, MA: Springer US, 2011.

A Simulações para mais configurações de dispositivos

Como sugerido, os métodos utilizados na Seção 3 (TTT e SVD) serão reaplicados aqui, em uma gama maior de condições de dispositivos.

A.1 Configurações

Serão testadas as seguintes configurações:

- Camada|Camada (C|C) - Idêntico à configuração em camadas da Seção 3.
- Camada|Bolha (C|B) - Fontes no leito em uma camada, e receptores em 3 camadas próximas à superfície de 9 dispositivos cada, emulando várias viagens de um ROV.
- Camada|Camada+Diagonal (C|CD) - Fontes no leito em uma camada, e duas viagens de receptores: uma camada horizontal próxima à superfície, e uma viagem na diagonal até 500m.
- Camada|Camada+Apêndice (C|CA) - Fontes no leito em uma camada, e duas viagens de receptores: uma camada horizontal próxima à superfície, e uma vertical até 500m no meio do ambiente.
- Camada|Garra (C|G) - Fontes no leito em uma camada, receptores em uma cada próxima à superfície, e receptores em dois apêndices próximos às laterais da viagem horizontal.
- Camada+Coluna|Camada+Coluna (CC|CC) - Semelhante à configuração no entorno da Seção 3, mas com mais dispositivos.
- Camada+Vertical|Camada (CV|C) - Fontes no leito em uma camada + alguns (poucos) verticalmente, e receptores na superfície em uma camada.
- Camada|Camada+Vertical (C|CV) - Fontes no leito em uma camada, e receptores na superfície em uma camada + alguns (poucos) verticalmente.
- Camada+Vertical|Camada+Vertical (CV|CV) - Fontes no leito em uma camada + alguns (poucos) verticalmente, e receptores na superfície em uma camada + alguns (poucos) verticalmente.
- Camada|Camada+Verticais (C|CCs) - Fontes no leito em uma camada, e receptores na superfície em uma camada + duas colunas.




Figura 10: Configurações dos dispositivos (fontes e receptores) para cada um dos casos.

As configurações referentes a cada um desses casos encontram-se na Fig. 10. Note que as configurações apresentam quantidades diferentes de dispositivos, em especial de fontes. Apesar de ser mais “justo” comparar configurações com quantidades iguais de dispositivos, a escolha aqui feita se inspirou na prática, em que não seria necessário reduzir a quantidade de medições (receptores) horizontais para medir na vertical, por exemplo.

Bem como nas simulações anteriores, aqui também foi feita uma hiper-otimização dos parâmetros de cada método em cada configuração, visando minimizar o erro de SSF (objetivo esse sendo implícito na otimização iterativa).

A.2 Visualização

Para facilitar visualização, os resultados serão apresentados para dois grupos diferentes:

Grupo 1 Consiste das 5 primeiras configurações (C|C, C|B, C|CD, C|CA, C|G), em que os receptores permanecem exclusivamente próximo à superfície (acima de 500m), e as fontes estão exclusivamente no leito.

Pelas conclusões desenhadas na Seção 3, espera-se que esse grupo desempenhe pior quando comparado ao outro, devido à falta de informação espacial atrelada às restrições impostas.

Nos gráficos, as configurações desse grupo serão representadas por cores mais frias (verdes/azuis).

Grupo 2 Consiste das 5 últimas configurações (CC|CC, CV|C, C|CV, CV|CV, C|CCs), em que ambos os dispositivos podem ser alocados ao longo de toda a profundidade. Novamente, essa liberdade de alocação dos dispositivos nos levaria a crer, pela heurística estabelecida, que o desempenho das técnicas nesse grupo seria melhor.

Nos gráficos, os resultados para as configurações desse grupo serão em cores mais quentes (amarelos/vermelhos).

Outras diferenciações Além das diferenciações por cores, cada técnica possui um marcador (SVD com triângulos, TTT com círculos), e cada configuração de dispositivos também conta com um estilo de tracejado diferente.

A.3 Análise geral

A Fig. 11 apresenta os resultados globais das métricas de erro RMS de tempo de trânsito e de velocidade do som (seguindo as mesmas métricas que mostradas na Seção 3.3), entre todas as configurações e técnicas.

Constatação 1

A técnica TTT, para as configurações no grupo 1 (menor informação espacial), não apresentou desempenho satisfatório de $RMSE_{SSF}$. No melhor caso, o resultado foi medíocre, e no pior implicaram em erros médios de mais de 100m/s.

Por outro lado, nessas mesmas configurações, a SVD alcançou desempenhos notável e estritamente superiores à TTT. Em específico, o pior desempenho dessa técnica foi nas configurações C|C e C|B, com o melhor desempenho para a configuração C|CA.

Constatação 2

Como já esperado — baseado nos resultados da Seção 3 — os resultados de ambas as técnicas para os casos do grupo 2 foram decididamente melhores que para o caso 1, tanto em $RMSE_t$ quanto (e aqui ainda mais perceptível) para $RMSE_{SSF}$.

Esse resultado se alinha com as conclusões obtidas anteriormente, reforçando a ideia de que a utilização de fontes somente próximo à superfície leva a uma falta de informação espacial, e disso uma estimação inapropriada do SSF.


Constatação 3

A Fig. 12 mostra um *scatterplot* entre os erros RMSE de tempo de trânsito (eixo x) e de velocidade (eixo y), para a última iteração do processo de minimização. É notável a correlação positiva entre ambas as métricas para as duas técnicas, em que um erro maior de tempo de trânsito implica em um erro maior de estimação de velocidade do som.


Nessa figura também é notável que, de forma geral, o desempenho do método SVD é próximo (grupo 2) ou superior (grupo 1) ao desempenho da TTT.

A.4 Análise por grupo

Enquanto na análise anterior a comparação foi realizada de maneira global, buscando tendências entre os grupos, aqui será feita uma análise para cada um dos grupos e técnicas. Além de separarmos por grupos, serão feitas também as seguintes alterações nos gráficos:



(a) Erro RMS de tempo de trânsito.



(b) Erro RMS do SSF.




Figura 11: Evolução dos erros RMS do processo de estimação do SSF, para os métodos TTT e SVD, nos cenários apresentados, ao longo de 10 iterações.




Figura 12: *Scatterplot* $RMSE_t$ vs $RMSE_{ssf}$, para os métodos TTT e SVD, nos cenários de dispositivos no perímetro e em camadas, ao longo de 10 iterações. Para facilitar visualização, o estilo da linha dos gráficos anteriores foi aplicado à borda dos marcadores aqui.

- 1) Serão analisados apenas os resultados para a SVD. Ficou claro anteriormente que o desempenho da SVD é superior ou igual ao da TTT ao longo das diferentes configurações. Portanto, de forma a reduzir a quantidade de dados a serem observados e discutidos, apenas a técnica com desempenho superior (SVD) será apresentada.
- 2) Serão apresentados apenas os erros RMSE de SSF. Pela análise anterior, constatou-se que há uma correlação positiva entre performance de redução do erro residual de tempo de trânsito, e performance de estimação do SSF. Além disso, como o objetivo intrínseco da minimização é a estimação do SSF, não há razão para reapresentar os dados de $RMSE_t$.

A Fig. 13 reapresenta os resultados para a SVD, nos 10 cenários apresentados, ao longo das iterações. De forma idêntica ao que foi discutido anteriormente, aqui fica ainda mais nítido que a performance das configurações do grupo 2 é superior que as do grupo 1, com um erro $\sim 5\times$ menor.

Constatação 4

É nítido que a melhor configuração de cada grupo é aquela com a maior quantidade de dispositivos (C|G com 243 raios para o grupo 1, e CC|CC com 324 raios para o grupo 2). Isso é reiterado na Fig. 14, em que agora realizamos um *scatterplot* entre a quantidade de medições de tempo de trânsito e o erro de SSF de cada configuração, para o método SVD, onde nota-se uma relação inversa entre número de medições e performance.




Figura 13: Evolução dos erros $RMSE_{ssf}$ do processo de estimação do SSF, para o método SVD, nos cenários apresentados, ao longo de 10 iterações.

Constatação 5

É interessante também comparar que diferentes configurações que possuem o mesmo número de medições ($C|CV \times CV|C$, $C|CD \times C|CA$, $C|B \times C|G \times C|CCs$) podem apresentar desempenhos nitidamente diferentes, e configurações com desempenhos semelhantes ($CC|CC \times C|CV \times CV|CV \times C|CCs$) necessitam de quantidades de medições também muito variáveis. Isso indica que só aumentar a quantidade de medições não necessariamente é o suficiente, sendo necessário escolher uma configuração adequada para alcançar determinada performance.

De qualquer modo, não nos aprofundaremos mais em uma análise quantitativa desses dados, tanto pela baixa quantidade de configurações testadas num geral, bem como pela otimização de hiperparâmetros do parâmetro regularizador da SVD. Como esse parâmetro depende fortemente do número de dispositivos, isso dificulta uma comparação qualitativa desses dados.

A.5 Erros de perfis

Por completude, apresentaremos também um *scatterplot* do SSP ao longo da profundidade. Enquanto o apresentado na Fig. 8 mostra um *scatterplot* do erro do SSP, aqui são mostrados os perfis. Apresentaremos somente para a SVD, pois essa foi a técnica mais extensamente discutida nessa seção. Além dos dados de velocidade estimados, cada figura também apresenta o perfil médio verdadeiro, que deseja-se estimar.

Os resultados da Fig. 8 revelam alguns ângulos que não podiam ser vistos tratando apenas dos erros




Figura 14: Número de raios vs $RMSE_{ssf}$, com o método SVD, nos cenários de dispositivos no perímetro e em camadas, ao longo de 10 iterações. Para facilitar visualização, o estilo da linha dos gráficos anteriores foi aplicado à borda dos marcadores aqui.

RMS das métricas.

Constatação 6

Todo os perfis para as configurações do grupo 1 (exceto C|C) se assemelham, e tem um semblante parecido com o esperado do perfil real (em preto). Isso indica que há uma certa quantidade de informação espacial, mas não suficiente para recuperar o perfil com fidedignidade.

Constatação 7

Semelhantemente, todos os perfis para as configurações do grupo 2 também se assemelham, e estes também melhor capturam as nuances do perfil desejado, quando comparados ao grupo 1. É nítido que a configuração de melhor desempenho de estimação do SSF é a CC|CC. Ainda assim, todas tiveram erros muito semelhantes, abaixo de 1.5m/s de erro médio.

Comparando com o grupo 1, nota-se que a adição de informação espacial provinda de dispositivos ao longo da coluna (e não somente na vertical próximo à superfície) melhora significativamente os resultados; contudo, aumentar essa informação espacial extra (aumentando o número de dispositivos) não leva a uma melhora significativa do desempenho.

Constatação 8

É interessante ver que, mesmo sem incorporar qualquer tipo de informação *a priori* sobre o perfil de velocidade desejado (como foi o caso nas técnicas apresentadas na Seções 4 e 5), essas inversões já conseguiram capturar razoavelmente o comportamento e as tendências dos perfis.





Figura 15: Erros de estimação de cada SSP, para o método SVD, para todas as configurações apresentadas, para a iteração final.

A.6 Resultados para parâmetros médios


Nas simulações anteriores dessa seção, em cada método (TTT e SVD) e configuração, foi utilizado o parâmetro obtido pela hiper-otimização, buscando minimizar o $RMSE_{SSF}$ final. Agora apresentaremos resultados para os valores médios dos parâmetros (para cada técnica), com a média sendo realizada sobre as 10 configurações realizadas. Para a TTT, foi usado $\alpha = 1.5437$, e para a SVD foi usado $\beta = 0.3671$. O objetivo desse resultado é comparar a robustez das técnicas à utilização de um parâmetro que não tenha sido escolhido especificamente para aquela configuração, e ver como ela se comporta para um parâmetro escolhido de maneira “genérica”.

Constatação 9


A ?? mostra os resultados de erro de tempo de trânsito e de erro de SSF para todas as configurações, as técnicas de TTT e SVD, para a situação sem otimização. Nota-se há um comportamento semelhante ao que foi visto anteriormente, em que o desempenho de ambos os métodos para as configurações do grupo 1



(a) Erro RMS de tempo de trânsito.



(b) Erro RMS do SSF.


 Figura 16: Evolução dos erros RMS do processo de estimação do SSF, para os métodos TTT e SVD, nos cenários apresentados, ao longo de 10 iterações, **sem otimização de hiper-parâmetros**.




Figura 17: Erros de estimação de cada SSP, para o método SVD, para todas as configurações apresentadas, para a iteração final, **sem otimização de hiper-parâmetros**.

são inferiores. Contudo, há também uma deterioração da performance dos métodos no grupo 2 que, embora ainda tenham um desempenho aceitável, são inferiores aos seus respectivos com hiper-otimização.

Também tem-se o mesmo resultado que anteriormente, em que a SVD obteve resultados melhores (no grupo 1) ou semelhantes (no grupo 2) à TTT.

Constatação 10

A Fig. 17 mostra os *scatterplots* para todas as configurações, com a SVD (por possuir desempenho superior ou igual), para o novo caso sem hiper-otimização.

A.7 Conclusões

Dos resultados apresentados, e das constatações e relações estabelecidas entre as métricas e os dados de cada configuração, fica claro que o uso de dispositivos (fontes e/ou receptores) ao longo de toda a profundidade (no

nosso caso, profundidade máxima de 1500m, devido às limitações dos dados utilizados) possui uma relação positiva com o desempenho da estimação do SSF.

Semelhantemente, a quantidade de medições também diretamente afeta o desempenho. Contudo, um aumento “cego” da quantidade de medições não necessariamente incute em uma melhora dos resultados (vide $C|CV \times CV|CV$).

Algo a ser considerado também é o “custo” de diferentes medições. Por exemplo, comparando $C|G$ com $C|CCs$, embora o erro de SSF com $C|G$ seja maior, as suas medições são todas próximas à superfície, enquanto $C|CCs$ necessita de uma grande quantidade de medições até a profundidade máxima. A depender de quão financeiramente custosas são essas medições profundas, o sacrifício de um erro maior pode ser válido e aceitável.

B Simulações com perfis até 5000m

As simulações previamente apresentadas mostravam os resultados da estimação do SSF para um ambiente até 1500m de profundidade com 31 células. De forma a avaliar os desempenhos em outro ambiente de interesse, agora será utilizado um recorte dos dados do WOA com 4900m de profundidade com 50 células, utilizando dados anuais. Foi necessário alterar o local tal que houvesse dados no WOA até tal profundidade, agora centrado em 36.375°S, 38.375°W.

As novas condições de distribuição dos dispositivos são tal como mostrado na Fig. 19. Foi mantido que, nas configurações do caso 1, os receptores somente poderiam viajar até 500m, dada que essa seria uma restrição externa dos dispositivos.

B.1 Resultados base

Os resultados-base de erro de tempo de viagem e erro do SSF estão na Fig. 20.

Constatação 1

Diferentemente do caso anterior (em particular, da Fig. 11), aqui temos que a TTT foi a técnica com os melhores desempenhos, tendo performances superiores para os casos do grupo 2, e empatando para as configurações do grupo 1. Isso é reiterado na Fig. 18.




Figura 18: *Scatterplot* $RMSE_t$ vs $RMSE_{ssf}$, para os métodos TTT e SVD, nos cenários de dispositivos no perímetro e em camadas, ao longo de 10 iterações. Para facilitar visualização, o estilo da linha dos gráficos anteriores foi aplicado à borda dos marcadores aqui.






Figura 19: Configurações dos dispositivos (fontes e receptores) para cada um dos casos.



(a) Erro RMS de tempo de trânsito.



(b) Erro RMS do SSF.




Figura 20: Evolução dos erros RMS do processo de estimação do SSF, para os métodos TTT e SVD, nos cenários apresentados, ao longo de 10 iterações.




Figura 21: Erros de estimação de cada SSP, para o método SVD, para todas as configurações apresentadas, para a iteração final, **sem otimização de hiper-parâmetros**.